

01 向量

1.8 向量范数

把方向各异的向量，映射为可以比较大小的标量



鸢尾花书·《线性代数不难》 | 开源代码与书稿: <https://github.com/Visualize-ML>

本节你将掌握的核心技能

1

理解向量范数的核心思想：用统一标准，把方向各异的向量映射为一个可比较大小的标量

2

掌握三种基本范数：L1（分量绝对值之和）、L2（勾股定理、欧几里得距离）、 L_∞ （分量绝对值最大值）

3

掌握 L_p 范数的一般形式：L1 到 L_∞ 的连续推广， $p \geq 1$

4

通过平面等距线、空间等距面，从几何角度直观理解不同范数的形状特征

5

理解向量范数与距离度量之间的关系，如欧氏距离、曼哈顿距离、切比雪夫距离


6

理解成对距离矩阵的结构：用矩阵统一存储任意两点之间的距离

7

了解 $0 < p < 1$ 时的特殊情况：等高线呈星形，但已不满足范数定义

本节知识脉络



向量的大小该如何比较？

$|x| = x$ 到原点的距离； $\|\mathbf{x}\|$ = 高维向量到原点的“距离”

- 数轴上，5 比 4 大；即便符号不同，比如 -5 和 4，也可以先取绝对值，再比较大小
- 绝对值本质上是数值与原点之间的距离；这一思路可以推广到二维、三维乃至更高维空间
- 为了让高维向量也能比较大小，我们引入向量范数（vector norm），先把向量映射为一个标量，再比较大小

L1 范数：分量绝对值之和

$$\|\mathbf{x}\|_1 = |x_1| + |x_2| + \dots + |x_n|$$

- L1 范数也称为曼哈顿距离（Manhattan distance）、城市街区距离（city block distance）
- 二维向量 $\mathbf{x} = [x_1, x_2]^T$ 的 L1 范数为 $\|\mathbf{x}\|_1 = |x_1| + |x_2|$
- 举例： $\mathbf{a} = [3, -4]^T$ 的 L1 范数为 $|3| + |-4| = 7$ ； $\mathbf{b} = [0, 5]^T$ 的 L1 范数为 $|0| + |5| = 5$ ，按 L1 范数， $\mathbf{a}$ 更大

NumPy 计算 L1 范数

两种等价写法，验证同一个结果

- 用 `np.array()` 定义向量 `a = [3, -4]`、`b = [0, 5]`
- `np.linalg.norm(a, ord=1)` 直接计算 L1 范数，`ord=1` 表示按 L1 范数规则求和
- `np.sum(np.abs(a))` 是等价写法：先取每个分量的绝对值，再求和，结果同为 7
- 同理计算 `b` 的 L1 范数，结果为 5，验证按 L1 范数 `a` 更大

```
## 初始化
import numpy as np


## 定义向量
a = np.array([3, -4])
b = np.array([0, 5])

## 计算 L1 范数
a L1_a = np.linalg.norm(a, ord=1)
b np.sum(np.abs(a))

L1_b = np.linalg.norm(b, ord=1)
np.sum(np.abs(b))
```

图1 • 二维向量 L1 范数平面等距线

- L1 范数的等距线 (iso-distance line) 是旋转正方形 (特殊的菱形), 满足 $|x_1| + |x_2| = c, c \geq 0$
- 黑色箭头为 $\mathbf{e}_1 = [1, 0]^T$ 、 $\mathbf{e}_2 = [0, 1]^T$, 二者的 L1 范数均为 1
- 在第一象限 ($x_1 > 0, x_2 > 0$), L1 范数为 1 的向量满足 $x_1 + x_2 = 1$; 请试着写出其余象限的表达式



绘制 L1 范数平面等距线

meshgrid 铺网格, *contour* 画等高线

- `np.meshgrid()` 生成覆盖整个平面的网格坐标点, 为逐点计算范数做准备
- `zz = np.abs(xx) + np.abs(yy)` 计算每个网格点的 L1 范数值
- `plt.quiver()` 绘制基向量 `e1`、`e2`;
`angles='xy'`、`scale_units='xy'` 让箭头长度与坐标轴单位一致
- `plt.contour(xx, yy, zz,`
`levels=np.arange(1, 9))` 画出 L1 范数从 1 到 8 的等距线, `cmap` 控制颜色渐变

```
## 初始化
import numpy as np
import matplotlib.pyplot as plt

## 生成数据
xx, yy = np.meshgrid(np.linspace(-8, 8, 1000),
                     np.linspace(-8, 8, 1000))

## 计算 L1 范数
zz = np.abs(xx) + np.abs(yy) # L1 范数计算公式

## 定义标准基向量
e1 = np.array([1, 0])
e2 = np.array([0, 1])

## 可视化
plt.figure(figsize=(6, 6))

# 绘制标准基向量 e1 和 e2
plt.quiver(0, 0, e1[0], e1[1],
           angles='xy', scale_units='xy',
           scale=1, color=[0, 0, 0],
           label='e1', zorder=1000)

plt.quiver(0, 0, e2[0], e2[1],
           angles='xy', scale_units='xy',
           scale=1, color=[0, 0, 0],
           label='e2', zorder=1000)

# 绘制 L1 范数的等距线
contour = plt.contour(xx, yy, zz,
                     levels=np.arange(1, 9),
                     cmap='RdYlBu_r')

# 添加 colorbar
cbar = plt.colorbar(contour)

# 设置坐标轴范围
plt.xlim(-8, 8); plt.ylim(-8, 8)

# 绘制网格和坐标轴
plt.axhline(0, color='black', linewidth=0.5)
plt.axvline(0, color='black', linewidth=0.5)
plt.xticks(np.arange(-8, 9, 2)); plt.yticks(np.arange(-8, 9, 2))
plt.grid(True, which='both', linestyle='--',
        linewidth=0.5, color='0.8')

# 设置等比例显示
plt.gca().set_aspect('equal', adjustable='box')
```



L2 范数：欧几里得范数，向量的“长度”

$$\|\mathbf{x}\|_2 = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$$

- L2 范数也称为欧几里得范数（Euclidean norm）、模，是物理世界中最常用的长度、距离度量
- 二维向量 $\mathbf{x} = [x_1, x_2]^T$ 的 L2 范数为 $\|\mathbf{x}\|_2 = \sqrt{x_1^2 + x_2^2}$
- 举例： $\mathbf{a} = [3, -4]^T$ 的 L2 范数为 $\sqrt{3^2 + (-4)^2} = 5$ ； $\mathbf{b} = [0, 5]^T$ 的 L2 范数为 $\sqrt{0^2 + 5^2} = 5$ ，两者相等

图2 • 二维向量 L2 范数平面等距线

- L2 范数的等距线是正圆，满足 $x_1^2 + x_2^2 = c^2$, $c \geq 0$
- LA_01_08_03.ipynb 计算并比较 **a**、**b** 的 L2 范数；
LA_01_08_04.ipynb 绘制本图，代码都很简洁，建议自学




L ∞ 范数：分量绝对值的最大值

$$\|\mathbf{x}\|_{\infty} = \max(|x_1|, |x_2|, \dots, |x_n|)$$

- L ∞ 范数也称为切比雪夫范数 (Chebyshev norm)
- 二维向量 $\mathbf{x} = [x_1, x_2]^T$ 的 L ∞ 范数为 $\|\mathbf{x}\|_{\infty} = \max(|x_1|, |x_2|)$
- 举例： $\mathbf{a} = [3, -4]^T$ 的 L ∞ 范数为 $\max(3, 4) = 4$ ； $\mathbf{b} = [0, 5]^T$ 的 L ∞ 范数为 $\max(0, 5) = 5$ ，按 L ∞ 范数， $\mathbf{b}$ 更大

图3 • 二维向量 L^∞ 范数平面等距线

- L^∞ 范数的等距线是正方形，满足 $\max(|x_1|, |x_2|) = c, c \geq 0$
- 正无穷在 NumPy 中用 `numpy.inf` 表示；请大家试着写代码绘制本图



Lp 范数: L1 到 L ∞ 的统一推广

$$\|\mathbf{x}\|_p = (|x_1|^p + |x_2|^p + \dots + |x_n|^p)^{1/p}, \quad p \geq 1$$

- 当 $p = 1, 2$ 时, Lp 范数分别退化为 L1、L2 范数; 当 p 趋向 $+\infty$ 时, Lp 范数趋向 L ∞ 范数
- 二维向量 $\mathbf{x} = [x_1, x_2]^T$ 的 Lp 范数为 $(|x_1|^p + |x_2|^p)^{1/p}$
- p 取不同值时, 平面上对应的等距线形状也随之连续变化

图4 • p 取不同值时, L_p 范数对应不同形状

- 当 p 从 1 增大到 $+\infty$ 时, 等距线由旋转正方形 (菱形) 逐渐过渡为圆形, 最终变为正方形
- p 越大, 图形边角越硬朗、越接近方形; $p = 2$ 时的圆形, 是唯一在所有方向上完全 “各向同性” 的形状





图5 • 向量 a 、 b 的 L_p 范数随 p 变化

- 向量 $a = [3, -4]^T$ 的 L_p 范数随 p 增大而不断减小：
 p 靠近 1 时各分量都参与贡献， p 趋向 $+\infty$ 时只剩最大绝对值分量
- 向量 $b = [0, 5]^T$ 只有一个非零分量，因此它的 L_p 范数恒为 5，不随 p 变化




L1、L2、L ∞ 范数为 1 的等距线在四点重合

$$\|\mathbf{x}\|_1 = \|\mathbf{x}\|_2 = \|\mathbf{x}\|_\infty = 1 \text{ 于 } (\pm 1, 0)、(0, \pm 1) \text{ 四点重合}$$

- L1、L2、L ∞ 范数为 1 的等距线（菱形、圆、正方形）都经过 (1,0)、(0,1)、(-1,0)、(0,-1) 四个点，三者在这些点上取值相同
- 除这四点外，同一位置处，随 p 增大，L p 范数逐渐变小
- 举例：全 1 向量 $\mathbf{1} = [1, 1]^T$ 的 L1 范数为 2，L2 范数为 $\sqrt{2}$ ，L ∞ 范数为 1，三者依次减小

图6 • L1、L2、L ∞ 范数为 1 的形状叠加

- 菱形 (L1 = 1)、圆 (L2 = 1)、正方形 (L ∞ = 1)
三条等距线在 (1,0)、(0,1)、(-1,0)、(0,-1) 处交汇
- 绿色箭头指向 $[1,1]^T$: 离开这四个交点后, 三种范数明显不再相等




固定 L_p 范数为 1，观察向量终点的变化

$$\|\mathbf{x}\|_p = 1, \quad p \text{ 从 } 1 \text{ 连续变化到 } +\infty$$

- 保持 L_p 范数恒为 1，观察 p 变化时，满足条件的一组向量终点轨迹如何变化
- 只有 (1,0)、(0,1)、(-1,0)、(0,-1) 四个方向上的向量，长度（ L_2 范数）恒为 1；其余方向上向量长度都会随 p 变化

图7 • 满足 L_p 范数为 1 的一组向量

- (a) L_1 范数为 1, 向量终点落在旋转正方形 (菱形) 上, 长度 (L_2 范数) 参差不齐, 仅四个轴向点长度为 1
- (b)(c) $L_{1.5}$ 、 L_2 范数为 1, 边角逐渐柔和, L_2 范数为 1 时终点恰好落在单位圆上, 长度全部相等
- (d)(e)(f) 当 p 增大到 3、5、 $+\infty$, 等距线越来越接近正方形, 边缘变陡, 其余方向上向量长度均大于 1



换个视角：固定单位向量，比较 L_p 范数


$\mathbf{x}$ 为单位向量 ($\|\mathbf{x}\|_2 = 1$)，观察 $\|\mathbf{x}\|_p$ 随 p 的变化

- 这组单位向量位于第一象限，与横轴夹角从 0° 连续变化到 45°
- $[1, 0]^T$ 的 L_p 范数恒为 1，不随 p 变化； $[\sqrt{2}/2, \sqrt{2}/2]^T$ 的 L_p 范数受 p 影响最为剧烈
- 当 p 趋向 1 时， $[\sqrt{2}/2, \sqrt{2}/2]^T$ 的 L_p 范数趋向 $\sqrt{2}$ ；当 p 趋向 $+\infty$ 时趋向 $\sqrt{2}/2$ ； $p = 2$ 时恰为 1


图8 • 单位向量的 L_p 范数随 p 变化

- (a) 一组水平面上的单位向量，夹角从 0° 到 45° 均匀分布， L_2 范数均为 1
- (b) 红色线 (0°) L_p 范数恒为 1；紫色曲线 (45°) 最“陡峭”，随 p 变化最剧烈

(a)



(b)



$$0 < p < 1$$

当 $0 < p < 1$ 时，还是范数吗？


$$\|\mathbf{x}\|_p = (|x_1|^p + |x_2|^p)^{1/p}, \quad 0 < p < 1$$

- 这一表达式在 $0 < p < 1$ 时依然可以画出等距线，但它已经不满足范数定义（不满足三角不等式，即次可加性）
- 等距线形状变得“尖锐”，呈现出类似星形的图案
- 这种几何形状虽然不是严格意义上的范数，但在某些优化问题、数据变换中仍有应用价值

$0 < p < 1$

图9 • 等距线, $p = 0.5$

- 当 $p = 0.5$ 时, 等距线呈现四瓣星形, 向坐标轴方向明显内凹
- 对比图1、图2、图3, 可以直观感受 $p < 1$ 与 $p \geq 1$ 在几何形状上的本质差异



三维向量的 L_p 范数

$$\mathbf{x} = [x_1, x_2, x_3]^T, \quad \|\mathbf{x}\|_p = (|x_1|^p + |x_2|^p + |x_3|^p)^{1/p}$$

- L_1 范数的等距面 (iso-distance surface) 是旋转正方体 (特殊的正八面体)
- L_2 范数的等距面是圆球; L_∞ 范数的等距面是正方体
- 从平面等距线到空间等距面, L_p 范数的几何直观可以自然推广到更高维空间

图10 • 三维向量 L_p 范数等距面随 p 变化

- p 取 1、1.5、2、3、5、20 时，等距面从正八面体逐渐过渡为圆球，最终趋近于正方体
- 这与二维平面上的变化规律完全一致，只是从“线”变成了“面”





图11 • 向量 $[2,3,6]^T$ 、 $[0,0,7]^T$ 的 L^p 范数随 p 变化

- $[2, 3, 6]^T$ 的 L^p 范数随 p 增大而不断减小, $[0, 0, 7]^T$ 只有一个非零分量, L^p 范数恒为 7
- 请大家自行计算这两个向量的 L^1 、 L^2 、 L^∞ 范数, 并与曲线两端的取值对照验证



RGB 颜色向量的 L_p 范数

红、绿、蓝三色向量 e_1 、 e_2 、 e_3 的 L_p 范数恒为 1，不受 p 影响

- 黄、品红、青三色向量（如 $[1,1,0]^T$ ）的 L_p 范数随 p 变化： p 趋向 1 时趋向 2， p 趋向 $+\infty$ 时趋向 1
- 白色向量 $[1,1,1]^T$ 的 L_p 范数： p 趋向 1 时趋向 3， p 趋向 $+\infty$ 时趋向 1

图12 • RGB 中常见颜色向量的 L^p 范数

- (a) RGB 立方体中红、绿、蓝、黄、品红、青、白等常见颜色向量
- (b)(c)(d) 分别对应 “单分量” 颜色、“双分量” 颜色、白色向量的 L^p 范数随 p 变化曲线





图13 • RGB 中 L1 范数为 1 的颜色向量

- 这组向量的终点都落在同一个平面上，满足 $x_1 + x_2 + x_3 = 1$
- 这正是 L1 范数等距面与第一卦限相交得到的三角形平面




图14 • RGB 中 L2 范数为 1 的颜色向量

- 这组向量的终点位于单位球面在第一卦限内的 $1/8$ 球面上
- 这正是我们最熟悉的“长度为 1”的几何定义，即欧几里得距离意义下的单位向量





图15 • RGB 中 L^∞ 范数为 1 的颜色向量 (含白色)

- 这组向量的终点都落在 RGB 颜色立方体中最鲜亮的三个立面上，白色向量也包含其中
- L^∞ 范数只关心分量中绝对值最大的那一个，因此立方体表面上的所有点范数都为 1




向量范数定义了向量之间的“距离”

$$a \text{ 与 } b \text{ 的距离} = \|a - b\|$$

- 给定平面上两个向量 a 、 b ，不特别强调的话，二者起点都在原点，这里的“距离”指两者终点之间的差异
- 选用不同的范数，就得到不同的距离定义：L2 范数对应欧几里得距离，L1 范数对应曼哈顿距离， L^∞ 范数对应切比雪夫距离

图16 • 三种不同的距离度量

- (a) 用 L_2 范数度量 a 、 b 的距离，即日常最直觉的“直线距离”
- (b) 用 L_1 范数度量距离，如同在方方正正的城市街道中步行，只能沿水平、垂直方向行走
- (c) 用 L_∞ 范数度量距离，取两个方向偏移量中最大的那个作为距离



用矩阵统一存储任意两点间的距离

26 个点，两两组合，共有 $C(26, 2) = 325$ 个距离值

- 平面上布置 26 个点，分别命名为 A、B、...、Z；其中 B 和 S 重叠，D 和 O 重叠
- 如此多的距离值，逐一记录并不现实；用矩阵存储，是最自然、最紧凑的方式
- 下一章将正式介绍“矩阵”这一概念：它不仅能存储成对距离，也在线性变换中扮演关键角色

图17 • 平面上 26 个点之间的两两欧氏距离

- 图中线条颜色深浅对应距离远近，B 与 S、D 与 O 两对点分别完全重合
- 图片来自《编程不难》





图18 • 成对欧氏距离矩阵

- 矩阵第 i 行、第 j 列的元素，代表第 i 个点与第 j 个点之间的欧氏距离
- 矩阵对角线上的元素全部为 0（每个点到自身的距离为 0），且矩阵关于对角线对称



本节关键术语

向量范数 *Vector Norm* — 把向量映射为可比较大小的标量的统一规则

L2 范数 *L2 Norm / Euclidean Norm* — 勾股定理, 向量的 “长度”

Lp 范数 *Lp Norm* — $L1$ 到 $L\infty$ 的连续统一推广, $p \geq 1$

次可加性 *Subadditivity* — 三角不等式 $\|a+b\| \leq \|a\| + \|b\|$, 范数的必要条件

曼哈顿距离 *Manhattan Distance* — 由 $L1$ 范数定义的 “街区式” 距离

L1 范数 *L1 Norm / Manhattan Distance* — 分量绝对值之和

$L\infty$ 范数 *$L\infty$ Norm / Chebyshev Norm* — 分量绝对值的最大值

等距线 / 等距面 *Iso-distance Line/Surface* — 范数值相同的点构成的图形

欧氏距离 *Euclidean Distance* — 由 $L2$ 范数定义的直线距离

成对距离矩阵 *Pairwise Distance Matrix* — 存储任意两点间距离的矩阵

配套代码与延伸阅读

代码1 • LA_Ch08_01_01.ipynb

计算向量的 $L1$ 范数，验证两种等价写法

代码2 • LA_01_08_02.ipynb

用 meshgrid、contour 绘制 $L1$ 范数平面等距线

延伸阅读 • LA_01_08_03/04.ipynb

计算并绘制 $L2$ 、 $L\infty$ 范数，建议自学

开源仓库

全书代码与图像素材：<https://github.com/Visualize-ML>

习题 Q1 – Q10

Q1 学习使用 Matplotlib 绘制等高线 (contour) , 并说明它与本节等距线的关系。

Q3 给定向量 $[1, 2, 3]^T$, 绘制该向量 L_p 范数随 p 变化的曲线。

Q5 请写 Python 代码复现图5、图11。

Q7 为什么 $0 < p < 1$ 时的表达式不是范数?

Q9 请用 `matplotlib.pyplot.contourf()` 试着绘制图1、图2、图3的填充等高线图。

Q2 给定向量 $[1, 2, 3]^T$, 手算其 L_1 、 L_2 、 L_∞ 范数。

Q4 比较以下成对向量在 p 取不同值时 L_p 范数的大小关系, 并解释原因: $[1,2,2]^T$ 与 $[0,0,3]^T$; $[2,4,4]^T$ 与 $[0,0,6]^T$; $[2,3,6]^T$ 与 $[0,0,7]^T$; $[1,4,8]^T$ 与 $[0,0,9]^T$ 。

Q6 什么是次可加性? 它和向量范数的定义有什么关系?

Q8 请计算以下颜色向量的 L_1 、 L_2 、 L_∞ 范数: 红色 $[1,0,0]^T$ 、黄色 $[1,1,0]^T$ 、白色 $[1,1,1]^T$ 。

Q10 编写函数 `lp_norm(x, p)` , 手动实现 L_p 范数的计算 (不调用 `np.linalg.norm`) , 并与 NumPy 结果对比验证。

习题 Q11 – Q20

Q11 用 `np.linalg.norm()` 分别计算向量 $[1, -2, 3, -4]^T$ 的 L_1 、 L_2 、 L_∞ 范数，并验证 $L_\infty \leq L_2 \leq L_1$ 。

Q13 用 Python 绘制 p 分别取 0.5、1、1.5、2、4、 $+\infty$ 时，二维平面上 L_p 范数等于 1 的等距线（仿图4）。

Q15 用 `scipy.spatial.distance` 中的 `euclidean`、`cityblock`、`chebyshev` 函数，验证与手写 L_2 、 L_1 、 L_∞ 距离公式的结果一致。

Q17 用 Matplotlib 绘制 26 个随机点及其成对欧氏距离连线图（仿图17），用颜色深浅表示距离远近。

Q19 编写函数 `rgb_norm_curve(color)`，绘制给定 RGB 颜色向量的 L_p 范数随 p 变化的曲线（仿图5、图12）。

Q12 编写代码，用随机向量验证不等式 $\|x\|_\infty \leq \|x\|_2 \leq \|x\|_1$ 对任意向量都成立。

Q14 编写函数 `iso_surface_3d(p)`，用 Matplotlib 三维绘图画出三维空间中 L_p 范数为 1 的等距面（仿图10）。

Q16 编写函数 `pairwise_distance_matrix(points, ord)`，输入一组二维点和范数类型，返回成对距离矩阵（仿图18）。

Q18 用 `seaborn.heatmap()` 或 `matplotlib.pyplot.imshow()` 可视化成对距离矩阵，并添加颜色条。

Q20 用 Python 验证：红、绿、蓝三个基础颜色向量的 L_p 范数恒为 1，不随 p 变化。

习题 Q21 – Q29

Q21 编写函数 `is_norm_p(p)`，通过随机采样多组向量，验证 $0 < p < 1$ 时三角不等式（次可加性）是否成立。

Q23 用 `sklearn.preprocessing.normalize()` 分别按 L1、L2 范数对一组随机向量做归一化，比较归一化后向量的方向是否改变。

Q25 编写函数 `unit_vectors_by_angle(n)`，生成 n 个夹角均匀分布在 $0^\circ \sim 90^\circ$ 的单位向量，绘制它们的 L_p 范数随 p 变化曲线（仿图 8）。

Q27 生成一个三维随机向量，分别计算其 L1、L2、 L_∞ 范数，并用三维散点图标出该向量相对图 10 等距面的位置。

Q29 综合运用本节知识，编写小程序：输入任意一组二维或三维点，输出它们两两之间的 L1、L2、 L_∞ 距离矩阵，并用热力图可视化其中一种。

Q22 用 Matplotlib 绘制 $p = 0.3$ 、 0.5 、 0.8 时的等距线，比较星形尖锐程度随 p 减小的变化趋势。

Q24 机器学习中 L1、L2 范数常用于正则化（regularization）。请查阅资料，用一两句话说明 L1 正则化为什么更容易产生稀疏解。

Q26 编写函数 `chebyshev_vs_manhattan(a, b)`，比较同一对向量在切比雪夫距离与曼哈顿距离下的比值，并对多组随机向量统计该比值的分布。

Q28 编写函数 `lp_norm_limit(x)`，用 $p = 100$ 、 1000 近似验证：当 p 趋向 $+\infty$ 时， L_p 范数的极限确实等于 L_∞ 范数。

10 个可深入探讨的 Prompt (1/2)

- 1 请解释为什么向量范数需要满足“次可加性”（三角不等式），如果不满足会带来什么问题？
- 2 请用生活中的例子解释 L_1 、 L_2 、 L_∞ 范数的直观差异，比如出租车行驶距离和直线距离的区别。
- 3 请证明：当 p 趋向 $+\infty$ 时， L_p 范数的极限确实收敛到 L_∞ 范数（分量绝对值的最大值）。
- 4 为什么 $0 < p < 1$ 时的表达式不满足范数定义？请从三角不等式的角度举一个反例。
- 5 请解释欧几里得距离、曼哈顿距离、切比雪夫距离在机器学习、路径规划中各自适用的场景。

10 个可深入探讨的 Prompt (2/2)


- 6 请设计一个 Python 小实验，验证同一对向量在不同范数下计算出的“距离”可能差异很大。
- 7 请解释为什么机器学习中的 L1 正则化容易产生稀疏解，而 L2 正则化更倾向于让权重均匀变小？
- 8 成对距离矩阵在数据科学中有哪些常见应用？比如聚类分析、推荐系统、最近邻搜索。
- 9 请解释为什么 RGB 空间中红、绿、蓝三个基础颜色向量的 L_p 范数恒为 1，不受 p 影响？
- 10 如果要在三维甚至更高维空间中可视化 L_p 范数的等距面，除了三维散点图，还有哪些可视化思路？

数学


数学基础

线性代数




概率统计



Python编程



数据可视化



工具

数据分析
图和网络

回归、降维
分类、聚类

实践

