

10 回归

10.3 多项式回归

用高次幂人造特征拟合非线性关系——设计矩阵、过拟合与二元多项式回归



鸢尾花书·《线性代数不难》 | 开源代码与书稿: <https://github.com/Visualize-ML>

本节你将掌握的核心技能

1

通过人为构造高次幂扩展特征，建模自变量与因变量间的非线性关系

2

理解多项式回归设计矩阵如何随阶数扩展

3

使用最小二乘公式计算多项式回归系数 b


4

理解欠拟合与过拟合，体会阶数与泛化能力之间的取舍

5

掌握二元甚至多元多项式回归，理解交叉项与高次组合

从人造非线性特征，到过拟合与二元多项式回归



本章每个回归话题，建议从这几方面看

- ① 几何视角：预测值是真实值向量在解释变量张成空间中的正交投影
- ② 代数视角：设计矩阵 $\mathbf{X}$ 、格拉姆矩阵 $\mathbf{X}^T \mathbf{X}$ 、广义逆 $(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$
- ③ 最优化视角：最小二乘——最小化残差平方和 $\|\boldsymbol{\epsilon}\|^2$
- ④ 统计视角：残差、拟合优度、显著性检验，留给《概率统计不难》深入讨论
- ⑤ 推广路径：从一元到二元、多元线性回归，再到非线性的多项式回归
- ⑥ 编程视角：手写矩阵公式与调用Scikit-Learn，结果完全一致
- ⑦ 应用场景：预测、趋势拟合、变量关系解释，是数据分析最基础的工具之一


有些数据散点呈现出线性回归无法很好拟合的弯曲趋势

$$y = b_0 + b_1x + \varepsilon \quad (\text{线性回归难以拟合弯曲趋势})$$

- 我们可以人为构造 x^2 、 x^3 等非线性特征，扩展为1、 x 、 x^2 、 x^3 等一组特征
- 这种做法就引出了多项式回归(polynomial regression)

图1 • 呈现“非线性”关系的散点数据

- 8个数据点随x增大呈现先升后降的弯曲趋势，直线难以贴合这种走势




一元多项式回归通过引入x的高次幂，拟合非线性数据关系

$$\hat{y} = b_0 + b_1x + b_2x^2 + \dots + b_mx^m$$

- b_2x^2 、...、 b_mx^m 都是“人造”特征；m设为1时，就退化为一元线性回归
- 一元线性回归可以看作一元多项式回归的特例

图2 · 一元多项式回归数据关系

- 常数1、 x 、 x^2 、...、 x^m 分别乘以系数 b_0 到 b_m ，加和得到 $\hat{y}$ ，与 y 相减得到残差 ε



多项式回归中，我们把x的不同阶数也当作额外特征列

$$X = [1 \ x \ x \odot x \ \dots \ x \odot x \odot x \odot x \odot x]$$

- $x \odot x$ 代表逐项积(element-wise product)，也叫阿达玛积(Hadamard product)
- 上式为一元五阶多项式回归的设计矩阵，向量是特殊的矩阵

图3 • 构造一元多项式回归中的设计矩阵

- 阶数从1到2再到5，设计矩阵不断加宽，新增列即为原列的逐项高次幂





图4 • 一元五次函数可以看作是6个图像叠加的结果

- 1、 x 、 x^2 、 x^3 、 x^4 、 x^5 各自的图像，按系数 b_0 到 b_5 叠加得到最终的弯曲曲线




求解多项式回归参数**b**，方法与多元线性回归完全一致

$$\mathbf{b} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

- 一元多项式回归中，设计矩阵X的列向量也张成一个多维向量空间
- 先算格拉姆矩阵 $\mathbf{X}^T \mathbf{X}$ 及其逆，构造广义逆 $(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$ ，再与y相乘得到b

图5 • 计算b，一元多项式回归

- X^T 与 X 相乘得到格拉姆矩阵 $X^T X$ ，取逆后与 X^T 相乘得到广义逆，再与 y 相乘得到 b



举个例子，阶数为2的一元多项式回归对应的模型为

$$\hat{y} = b_0 + b_1x + b_2x^2$$

- 沿用图1中的8个散点数据： $x=[1,2,4,5,6,7,8,9]^T$, $y=[1,7,8,6,5,2,2,4]^T$
- “二次”指模型中含有x的平方项，多项式中最高次数即为多项式的次数


一元二次多项式回归设计矩阵X为

$$X = [1 \ x \ x \odot x] \quad (n=8 \text{ 行}, 3 \text{ 列})$$

- 第一列全1，第二列为x原始取值，第三列为x逐项平方 $x \odot x$

图6 • y 朝 $\text{span}(1, x, x \odot x)$ 投影，一元二次多项式线性回归

- $\hat{y}$ 是1、 x 、 $x \odot x$ 三个向量的线性组合，误差 $\varepsilon = y - \hat{y}$ 垂直于该超平面




代入广义逆公式，得到一元二阶多项式回归模型

$$\hat{y} = 1.655 + 1.927x - 0.214x^2$$

- 解得 $b = [1.655, 1.926, -0.214]^T$ ，图7中的红色抛物线对应该解析式

图7 • 阶数为2的一元多项式回归

- 橙色线段为误差 $\varepsilon = y - \hat{y}$ ，误差平方和 $\|\varepsilon\|^2 = \varepsilon^T \varepsilon = 30.040$ ，拟合仍不够贴合




较低阶数无法很好捕捉复杂关系，把阶数提高到3！

$$\hat{y} = b_0 + b_1x + b_2x^2 + b_3x^3$$

- 请大家自行写出一元三次多项式回归设计矩阵X，并计算b
- 解得 $\hat{y} = -8.539 + 12.211x - 2.643x^2 + 0.16x^3$

图8 • 阶数为3的一元多项式回归

- 红色曲线比图7更贴合数据，误差平方和 $\|\epsilon\|^2=1.302$ ，比二次多项式明显减小



过拟合

较高阶数可能导致过拟合，丧失泛化能力

欠拟合 就像“学业不精”——只掌握皮毛，连基础题都常做错，说明学习内容太少太浅

过拟合 就像“死读书”——死记硬背例题解法，题型稍变或结合实际就无所适从

好的状态 在训练集和测试集上都表现良好，既掌握规律，又具备灵活应变的能力

阶数为8


图9所示为阶数为8的一元多项式回归结果，对应的解析式为

$$\hat{y} = 7.123 - 11.430x - 2.828x^2 + 15.342x^3 - 9.463x^4 + \dots$$

- 阶数越高，模型越能够适应训练数据，但也更容易在新数据上表现不佳

图9 · 阶数为8的一元多项式回归


- 红色曲线“完美”穿越了所有数据点，误差几乎为0，但这并不是理想的模型



用Python求解三次多项式回归

手写公式 $b = \text{inv}(X.T@X)@X.T@y$ 求解阶数为3的模型

- (a) 构造一元回归自变量、因变量数据x、y
- (b) 拼接设计矩阵 $X=[1, x, x \odot x, x \odot x \odot x]$ ，共4列
- (c) 计算 $b=\text{inv}(X^T X)@X^T@y$ ，即最小二乘解析解
- (d) 用b计算预测值 $\hat{y}=Xb$ ，以及残差 $\varepsilon=y-\hat{y}$
- (e) 绘制散点、拟合曲线与误差线段，对应图8



用Scikit-Learn自动完成多项式特征与回归

请大家自学LA_10_03_02.ipynb：用sklearn.preprocessing的PolynomialFeatures自动生成高次特征

再用sklearn.linear_model的LinearRegression完成阶数为8的回归，绘制图9，并与手写结果比较


把变量扩展到两个 x_1 、 x_2 ，就可以构造二元多项式回归

$$\hat{y} = b_0 + b_1x_1 + b_2x_2 + b_3x_1^2 + b_4x_2^2 + b_5x_1x_2$$

- 除了原始的 x_1 、 x_2 ，还引入 x_1^2 、 x_2^2 以及交叉项 x_1x_2 等组合
- 这个模型既能拟合两个自变量的线性关系，也能捕捉它们之间的非线性交互

图10 • 二元二次多项式中各项图像

- 上式相当于6个曲面的叠加：常数项、 x_1 、 x_2 、 x_1^2 、 x_2^2 ，以及交叉项 x_1x_2



二元二次多项式回归可以写成矩阵乘法形式

$$\hat{y} = [1 \ x_1 \ x_2 \ x_1 \odot x_1 \ x_2 \odot x_2 \ x_1 \odot x_2] [b_0; \dots; b_5]$$

- 这意味着二元二次多项式回归的设计矩阵X为 $[1 \ x_1 \ x_2 \ x_1 \odot x_1 \ x_2 \odot x_2 \ x_1 \odot x_2]$

继续扩展次数

阶数继续增加，构造出的特征会更多

看二元三次多项式回归，构造出的特征会更多，包括三次项

随着次数增多，我们不断纳入更多的高次项，如图11所示

通过这些人工构造的特征，模型可以更好地拟合曲面状的复杂数据分布

图11 • 多项式中的不同次数的项

- 表格按行列组合列出 1 、 x_1 、 x_1^2 、 x_1^3 与 1 、 x_2 、 x_2^2 、 x_2^3 两两相乘得到的各阶项

	1	x_2	x_2^2	x_2^3	...
1	1	x_2	x_2^2	x_2^3	
x_1	x_1	$x_1 x_2$	$x_1 x_2^2$	$x_1 x_2^3$	
x_1^2	x_1^2	$x_1^2 x_2$	$x_1^2 x_2^2$	$x_1^2 x_2^3$	
x_1^3	x_1^3	$x_1^3 x_2$	$x_1^3 x_2^2$	$x_1^3 x_2^3$	
$\vdots$					

二次项部分可以写成矩阵乘法形式，这是二次型(quadratic form)

$$b_3x_1^2 + b_4x_2^2 + b_5x_1x_2 = x^T [b_3 \ b_5/2; b_5/2 \ b_4] x$$

- 这是本书后续要介绍的二次型，多项式回归的交叉项正是二次型的雏形

从一元到二元多项式回归，我们看到了什么？

多项式回归通过人为构造 x 的高次幂，把非线性关系转化为线性回归问题

设计矩阵随阶数增加而加宽，新增列是原列的逐项高次幂
 $x \odot x \odot \dots$

求解方法与多元线性回归完全一致： $b = (X^T X)^{-1} X^T y$

阶数越高，训练误差越小，但阶数过高会导致过拟合，丧失泛化能力

二元多项式回归引入交叉项 $x_1 x_2$ ，可以捕捉变量间的非线性交互

二次项部分可以写成二次型 $x^T A x$ 的形式，为后续章节埋下伏笔

本节关键术语

多项式回归 *Polynomial Regression* —— 引入自变量高次幂拟合非线性关系的回归模型

逐项积/阿达玛积 *Element-wise Product / Hadamard Product*, 记为 $x \odot x$

格拉姆矩阵、广义逆 *Gram Matrix $X^T X$, Generalized Inverse $(X^T X)^{-1} X^T$*

过拟合 *Overfitting* —— 模型在训练集上表现很好, 但在新数据上表现较差

交叉项 *Cross Term* —— 如 $x_1 x_2$, 刻画两个自变量之间的交互作用

阶数 *Degree* —— 多项式中最高次数, 记为 m

设计矩阵 *Design Matrix X* —— 各列分别为1、 x 及其逐项高次幂

欠拟合 *Underfitting* —— 模型过于简单, 训练集和测试集上表现都不好

泛化能力 *Generalization Capability* —— 模型对新数据的预测能力

二次型 *Quadratic Form* —— $x^T A x$, 本书后续章节将展开讨论

延伸阅读

回顾 · 10.2 多元回归

多项式回归求解 b 的方法与多元线性回归完全一致，建议平行阅读

延伸阅读 · 二次型

本书后续章节将系统介绍二次型 $x^T A x$ 及其几何意义

延伸阅读 · 《机器学习》

图4来自《机器学习》一书，可延伸阅读过拟合与正则化相关内容

开源仓库

全书代码与图像素材：<https://github.com/Visualize-ML>

习题 Q1 – Q9

Q1 已知代码产生一元回归自变量、因变量数据，请用Python编程计算一元3阶多项式回归中的 b 、 $\hat{y}$ 、 ϵ 。

Q3 为什么 m 设为1时，一元多项式回归会退化为一元线性回归？

Q5 为什么多项式回归本质上仍是线性回归？线性体现在哪里？

Q7 阶数从2提升到3时，误差平方和 $\|\epsilon\|^2$ 为什么会减小？是否会一直减小？

Q9 阶数为8的多项式为什么能“完美”穿越所有训练点？这说明了什么问题？

Q2 用sklearn.preprocessing的PolynomialFeatures和sklearn.linear_model的LinearRegression求解Q1，并比较结果。

Q4 写出一元四阶多项式回归的设计矩阵 X ，说明每一列的含义。

Q6 证明：一元二次多项式回归中，误差向量 ϵ 与设计矩阵每一列都正交。

Q8 用自己的语言解释欠拟合与过拟合的区别，并各举一个生活中的类比。

习题 Q10 – Q17

Q10 用numpy构造一元五阶多项式回归的设计矩阵X，并计算其格拉姆矩阵 $X^T X$ 。

Q12 对同一份数据分别拟合阶数为1到8的多项式回归，绘制误差平方和随阶数变化的曲线。

Q14 构造二元二次多项式回归的设计矩阵X，并用代码验证其列数。

Q16 用matplotlib可视化不同阶数多项式回归的拟合曲线，叠加在同一张图上对比。

Q11 写Python函数poly_design_matrix(x, m)，返回一元m阶多项式回归的设计矩阵。

Q13 写出二元三次多项式回归的解析式，包含哪些特征列？

Q15 验证二次型 $x^T [[b_3, b_5/2], [b_5/2, b_4]] x$ 展开后是否等于 $b_3 x_1^2 + b_4 x_2^2 + b_5 x_1 x_2$ 。

Q17 写Python函数mse(y, y_hat)，计算均方误差，并用它比较不同阶数模型的表现。

习题 Q18 – Q25

Q18 探索：把数据集划分为训练集和测试集，分别计算不同阶数模型在两个集合上的误差。

Q20 用sklearn.preprocessing的PolynomialFeatures生成二元二次多项式特征，并打印特征名称。

Q22 用代码验证：图4中六条曲线叠加后是否等于图4底部的组合曲线。

Q24 探索多项式回归在实际数据集中的应用：选择一个非线性关系明显的变量对，拟合并可视化。

Q19 观察随阶数增加，训练误差和测试误差如何变化，尝试画出“U形”曲线。

Q21 探索：加入L2正则化(Ridge回归)，观察高阶多项式回归的过拟合是否得到缓解。

Q23 综合练习：写Python函数predict_poly(x_new, b, m)，对新数据做m阶多项式预测。

Q25 预习思考：下一章将介绍特征值分解，它与本节的格拉姆矩阵 $X^T X$ 有什么联系？

10个可以和AI互动的Prompt

- 1 请解释为什么多项式回归本质上仍是线性回归，线性体现在对参数 b 而不是对 x 。
- 2 请解释多项式回归设计矩阵中 $x \odot x$ (Hadamard积) 的含义，以及它和 x^2 的关系。
- 3 请用Python演示：如何从一元线性回归的设计矩阵扩展到 m 阶多项式回归的设计矩阵。
- 4 请解释欠拟合与过拟合各自对应模型复杂度的哪个区间，如何用误差曲线判断。
- 5 请解释为什么阶数越高，训练误差通常越小，但测试误差不一定越小。

10个可以和AI互动的Prompt

6 请解释二元多项式回归中交叉项 x_1x_2 的几何含义，它刻画了怎样的变量交互。

7 请解释二次型 $x^T Ax$ 与多项式回归中二次项之间的对应关系。

8 请解释sklearn中PolynomialFeatures的作用，以及它和手写设计矩阵的关系。

9 请解释为什么正则化（如岭回归）可以缓解高阶多项式回归的过拟合问题。






10 请用Python可视化：同一份数据分别用阶数1、3、8的多项式拟合，对比过拟合现象。

数学

数学基础

线性代数


概率统计



Python编程

数据可视化

工具



数据分析
图和网络

回归、降维
分类、聚类

实践