

11 特征值分解

11.1 特征值分解

特征值是方阵“自身值”，特征向量是方阵“自身方向”——手解特征值分解



鸢尾花书·《线性代数不难》 | 开源代码与书稿: <https://github.com/Visualize-ML>

本节你将掌握的核心技能

1 特征向量是在方阵线性变换下方向不变的非零向量

2 特征值表示特征向量在变换中被缩放的倍数


3 掌握用特征多项式手解特征值分解

4 某一特征值的所有特征向量构成一条过原点的直线

5 某个方阵可对角化，当且仅当它所有特征向量线性无关

6 实对称矩阵的特征分解称为谱分解

从 $Av=\lambda v$ ，到手解特征值分解，再到谱分解



本章每个特征值分解话题，建议从这几方面看

① 几何视角：特征向量是方阵变换下方向不变的向量，特征值是对应的缩放倍数

② 代数视角：特征多项式 $\det(\mathbf{A}-\lambda\mathbf{I})=0$ ，可对角化 $\mathbf{A}=\mathbf{V}\mathbf{\Lambda}\mathbf{V}^{-1}$

③ 对称矩阵：谱分解 $\mathbf{A}=\mathbf{V}\mathbf{\Lambda}\mathbf{V}^T$ ，几何上是“旋转→缩放→旋转”

④ 非对称矩阵：特征值分解不再是正交变换，特征向量也未必正交

⑤ 应用视角：格拉姆矩阵、协方差矩阵的特征分解，是主成分分析的数学基础

⑥ 编程视角：用`numpy.linalg.eig`计算特征值、特征向量，并验证分解结果

⑦ 推广路径：从特征值分解，到下一章的奇异值分解(SVD)

什么是特征值？什么是特征向量？

特征值分解就是找到方阵A的特征值 λ 、对应特征向量 v ，满足


$$Av = \lambda v$$

- “特征”源自德语 “eigen”，意思是“自身的”或“固有的”
- 特征向量 v 被A作用得到向量 λv ，在A作用下 v 方向不变（或正向或反向）

$$AV = \Lambda V$$

图1 • $Av = \lambda v$, 矩阵A形状为 2×2

- 特征值 λ 决定缩放大小, λ 的正负决定输出向量是与 v 同向还是反向



举个例子


给定 2×2 方阵A，让A对图中单位向量进行线性变换

$$A = \begin{bmatrix} 5/4 & -3/4 \\ -3/4 & 5/4 \end{bmatrix}$$

- 特征向量默认为非零向量，因为 $A\mathbf{0}=\mathbf{0}$ 意味着“原点不变”，没有探讨价值；但特征值可以为0

图2 • 一组单位向量

- 平面上起点位于原点的单位向量，终点都落在单位圆的圆周上，如 e_1 、 e_2



A作用于 E_1 、 E_2


A作用于单位向量 e_1 、 e_2 ，大小、方向都发生了变化

$$Ae_1 = [5/4; -3/4] \quad Ae_2 = [-3/4; 5/4]$$

- 关注标准正交基 $[e_1, e_2]$ ，是想看单位正方形网格变成怎样的平行四边形网格
- 请大家计算A的行列式，观察变换前后面积的变化

图3 • 矩阵A对一组单位向量的线性变换

- 单位圆变成旋转椭圆，单位正方形网格变成了倾斜的平行四边形网格




仔细观察，有几个特殊向量方向不变，仅长度发生缩放

$$Av_1 = 2v_1$$

- 单位向量 v_1 （品红色）经过A线性变换后，方向不变，长度缩放为原来的2倍
- 这告诉我们， v_1 是A的特征向量，对应的特征值 $\lambda_1=2$

图4 • 矩阵A的特征向量

- v_1 (品红)、 v_2 (橙色) 经过A变换后方向不变, 分别对应特征值 $\lambda_1=2$ 、 $\lambda_2=0.5$




特征值、特征向量成对匹配，但给定特征值对应的特征向量不唯一

$$A(-\mathbf{v}_1) = 2(-\mathbf{v}_1) \quad A(k\mathbf{v}_1) = 2(k\mathbf{v}_1)$$

- 反向量 $-\mathbf{v}_1$ 、任意非零标量 k 缩放 $k\mathbf{v}_1$ ，都是 $\lambda_1=2$ 对应的特征向量
- 所有特征向量构成一条过原点的直线；本书特征向量默认经过单位化

图5 • 特征向量不唯一

- 任意非零标量 k 缩放的结果，仍是 $\lambda_1=2$ 这个特征值对应的特征向量



另一个特征向量

$\mathbf{v}_2$ （橙色）也是A的特征向量，对应特征值 $\lambda_2=0.5$

$A\mathbf{v}_2=0.5\mathbf{v}_2$ ；请大家在图5上画出 $\lambda_2=0.5$ 这个特征值对应的特征向量所在直线

单位圆变成了旋转椭圆！这背后的数学原理，是本书第13章要讨论的话题

把 $Av = \lambda v$ 整理成 $(A - \lambda I)v = 0$ ， $v \neq 0$ 意味着 $A - \lambda I$ 的行列式为0

$$(A - \lambda I)v = 0 \quad \det(A - \lambda I) = 0$$

- v 为非零单位向量，经过 $A - \lambda I$ 降维后得到零向量，因此 $A - \lambda I$ 不满秩


$\det(A-\lambda I)$ 对应的多项式，叫做特征多项式(characteristic polynomial)

$$\lambda^2 - 5/2\lambda + 1 = 0$$

- 令特征多项式为0，如图6所示，二次方程满足 $b^2-4ac \geq 0$ 时有两个实数根

图6 • 二次函数和二次方程的根

- 求根公式 $x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$ ，代入特征多项式即可求得特征值



据此，A的两个特征值为

$$\lambda_1 = 2 \quad \lambda_2 = 1/2$$

- 对于 $\lambda_1=2$ ，令 $v_1=[x_1, x_2]^T$ 代入 $(A-\lambda I)v=0$ ，得到一个齐次线性方程组

整理后得到 $x_1 + x_2 = 0$ ，这是一条过原点的直线


齐次线性方程组：常数项全为0，即 $Ax=b$ 中 b 为零向量；永远至少有零解

除了零解，齐次线性方程组还可能有无穷多个非零解

任何在 $x_1 + x_2 = 0$ 这条直线上的非零向量，都是 $\lambda_1 = 2$ 对应的特征向量

图7 • 两条（过原点的）直线

- $x_1 + x_2 = 0$ 、 $x_1 - x_2 = 0$ 恰好过原点，且在平行四边形网格线的交点上



对于 $\lambda_2=0.5$ ，同样代入求解，整理后得到 $x_1-x_2=0$

$$\mathbf{v}_1 = [\sqrt{2}/2; -\sqrt{2}/2] \quad \mathbf{v}_2 = [\sqrt{2}/2; \sqrt{2}/2]$$

- 选择 $\mathbf{v}_1$ 在第四象限、 $\mathbf{v}_2$ 在第一象限的单位向量，让 $\mathbf{v}_1$ 逆时针领先 $\mathbf{v}_2$ ， $V=[\mathbf{v}_1, \mathbf{v}_2]$ 行列式为正

写成矩阵乘法形式

整理两个矩阵乘法 $AV=V\Lambda$ ，如果 V 满秩，可以把 A 写成

$$A = V\Lambda V^{-1}$$

- V 右侧乘对角方阵 Λ ，相当于对 V 的列向量完成缩放
- 能写成这种分解形式的矩阵，叫可对角化矩阵(diagonalizable matrix)

存在特征值、特征向量，不代表方阵一定可以对角化

特征向量线性无关，是可对角化的重要条件，即 V 可逆

方阵 A 列向量线性无关，不代表 A 的特征向量线性无关

只有特征向量线性无关时， V 才存在逆矩阵， A 才能写成 $V\Lambda V^{-1}$

旋转 → 缩放 → 旋转

本例中V正是本书前文讲解过的旋转矩阵，且V是正交矩阵

$$V^{-1} = V^T \quad A = V\Lambda V^T$$

- 本例A特征值分解结果的几何变换为 “旋转→缩放→旋转”
- 产生这种特殊变换的原因，是因为A是对称矩阵

对称矩阵的特征值分解，有自己的名字——谱分解

谱分解(spectral decomposition)专指实对称矩阵的特征值分解
，是下一节要讲的话题

注意，非对称矩阵的特征值分解不是“旋转→缩放→旋转”

用Python完成特征值分解

`lambdas, V = np.linalg.eig(A)` 计算特征值、特征向量

- (a) 用`numpy.linalg.eig`计算A的特征值、特征向量, `numpy.diag`构造对角矩阵
- (b) 从特征值列表中取出第一个特征值
- (c) 从特征向量矩阵V中取第一列, 双中括号保持二维列向量形式
- (d)(e) 对第二组特征值、特征向量完成相同操作
- (f) 用`V@Λ@inv(V)`检验分解结果; 本例中V可逆, 因此A可以对角化

```
## 初始化
import numpy as np
import matplotlib.pyplot as plt

## 构造矩阵
A = np.array([[1.25, -0.75],
              [-0.75, 1.25]])

## 特征值分解
a lambdas, V = np.linalg.eig(A)
  Lambda = np.diag(lambdas)

## 第一组特征值、特征向量
# 特征值
b lambda_1 = lambdas[0]
# 特征向量
c v_1 = V[:, [0]]
  A @ v_1
  lambda_1 * v_1

## 第二组特征值、特征向量
# 特征值
d lambda_2 = lambdas[1]
# 特征向量
e v_2 = V[:, [1]]
  A @ v_2
  lambda_2 * v_2

## 特征值分解
f V @ Lambda @ np.linalg.inv(V)
```

小结

关于特征值分解，我们看到了什么？

特征值分解找到方阵A的特征值 λ 、特征向量 v ，满足 $Av=\lambda v$

特征向量在A的变换下方向不变，特征值决定缩放倍数与正反向

求解特征值：令特征多项式 $\det(A-\lambda I)=0$ ，解出 λ

求解特征向量：代入 λ ，解齐次线性方程组 $(A-\lambda I)v=0$

特征向量线性无关时，A可对角化， $A=V\Lambda V^{-1}$

对称矩阵的特征值分解是“旋转→缩放→旋转”，有专门名字——谱分解

本节关键术语

特征值分解 *Eigenvalue Decomposition, EVD* —— 找到方阵的特征值与特征向量

特征向量 *Eigenvector v* —— 变换下方向不变的非零向量，默认单位化

齐次线性方程组 *Homogeneous System* —— 常数项全为0的线性方程组 $Ax=0$

对角方阵 Λ 由特征值构成的对角矩阵

旋转矩阵、正交矩阵 谱分解中 V 的几何身份，满足 $V^{-1}=V^T$

特征值 *Eigenvalue λ* —— 特征向量在变换中被缩放的倍数，可以为0

特征多项式 *Characteristic Polynomial* —— $\det(A-\lambda I)=0$ 对应的多项式

可对角化矩阵 *Diagonalizable Matrix* —— 能写成 $A=V\Lambda V^{-1}$ 的方阵

谱分解 *Spectral Decomposition* —— 实对称矩阵的特征值分解， $A=V\Lambda V^T$

行列式 *Determinant* —— 反映线性变换前后面积（或体积）的缩放比例

延伸阅读

延伸阅读 · 11.2 谱分解

下一节将系统介绍实对称矩阵的特征值分解——谱分解

延伸阅读 · 11.3 非对称方阵EVD

非对称矩阵的特征值分解不再是“旋转→缩放→旋转”

回顾 · 旋转矩阵与正交矩阵

本节谱分解的几何直觉建立在正交矩阵的基础上，建议回顾

开源仓库

全书代码与图像素材：<https://github.com/Visualize-ML>

习题 Q1 – Q9

Q1a 手算矩阵 $\begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$ 的特征值分解，并用Python验证。

Q1c 手算矩阵 $\begin{bmatrix} 1/2 & 0 \\ 0 & 2 \end{bmatrix}$ 的特征值分解，并用Python验证。

Q1e 手算矩阵 $\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ 的特征值分解，并用Python验证。

Q2 指出Q1中哪些方阵可以对角化，哪些不可以，并说明理由。

Q4 证明：同一特征值对应的所有特征向量（加上零向量）构成一个子空间。

Q1b 手算矩阵 $\begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$ 的特征值分解，并用Python验证。

Q1d 手算矩阵 $\begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}$ 的特征值分解，并用Python验证。

Q1f 手算矩阵 $\begin{bmatrix} 1/2 & 1/2 \\ 1/2 & 1/2 \end{bmatrix}$ 的特征值分解，并用Python验证。

Q3 为什么特征向量一般要求非零？特征值是否也必须非零？举例说明。

习题 Q10 – Q17

Q10 写出 2×2 方阵A的特征多项式的一般表达式，用A的迹和行列式表示。

Q12 构造一个 2×2 对称矩阵，手解其特征值分解，验证特征向量是否正交。

Q14 构造一个特征值有重根的 2×2 矩阵，观察它是否仍然可以对角化。

Q16 证明：如果 v 是A的特征向量，那么 v 也是 A^2 的特征向量，对应特征值是 λ^2 。

Q11 证明：方阵A的所有特征值之和等于A的迹，所有特征值之积等于A的行列式。

Q13 写Python函数`eig_2x2(A)`，手写特征多项式求解 2×2 矩阵的特征值。

Q15 用matplotlib绘制矩阵A对单位圆的线性变换，并标出特征向量方向。

Q17 探索：旋转矩阵（无实数特征值的情形）在实数域内是否一定有特征向量？

习题 Q18 – Q25

Q18 用`numpy.linalg.eig`验证Q12中手解结果是否一致。

Q20 写Python函数`is_diagonalizable(A)`，通过判断特征向量矩阵是否可逆来给出结论。

Q22 构造一个奇异矩阵（不满秩），观察它的特征值中是否一定包含0。

Q24 探索：如果A可逆，A的特征值与 A^{-1} 的特征值之间有什么关系？请证明并用代码验证。

Q19 探索：三角矩阵（上三角或下三角）的特征值有什么规律？请用代码验证。

Q21 探索：单位矩阵I的特征值、特征向量分别是什么？有什么特殊之处？

Q23 综合练习：写Python函数`verify_evd(A, lambdas, V)`，检验 $A@V$ 是否等于 $V@diag(lambdas)$ 。

Q25 预习思考：下一节谱分解中，对称矩阵的特征向量为什么天然正交？

10个可以和AI互动的Prompt

1 请解释特征值、特征向量的几何含义，为什么说特征向量是方阵的“自身方向”。

2 请解释为什么特征向量默认要求非零，而特征值却可以为0。

3 请解释特征多项式 $\det(A-\lambda I)=0$ 是如何推导出来的，每一步的几何含义是什么。

4 请用Python演示：如何手写代码求解一个 2×2 矩阵的特征值和特征向量。

5 请解释为什么同一特征值对应的特征向量不唯一，它们构成怎样的几何形状。

10个可以和AI互动的Prompt






- 6 请解释矩阵可对角化的条件，为什么特征向量线性无关是关键。
- 7 请解释为什么对称矩阵的特征值分解可以理解为“旋转→缩放→旋转”。
- 8 请解释谱分解与一般特征值分解的区别，为什么谱分解只适用于对称矩阵。
- 9 请解释特征值分解 $A=V\Lambda V^{-1}$ 与矩阵乘法 $AV=V\Lambda$ 之间的关系。
- 10 请用Python可视化：一个 2×2 矩阵对单位圆的线性变换，并标出特征向量方向。

数学

数学基础

线性代数


概率统计



Python编程

数据可视化

工具



数据分析
图和网络

回归、降维
分类、聚类

实践