

11 特征值分解

11.4 格拉姆矩阵

从内积、 $L2$ 范数到谱分解、正交化，再到奇异值分解——格拉姆矩阵是贯穿整本书的核心角色



鸢尾花书 · 《线性代数不难》 | 开源代码与书稿: <https://github.com/Visualize-ML>

本节你将掌握的核心技能

1 格拉姆矩阵为对称矩阵，半正定、正定

2 格拉姆矩阵和原矩阵列向量内积关系

3 主对角线元素为列向量L2范数的平方


4 格拉姆矩阵的谱分解

5 通过正交矩阵，完成原矩阵的正交化

6 根据特征值大小判断特征向量的“解释力”，理解主次之分

7 格拉姆矩阵的谱分解和奇异值分解的关系

从 $G=ATA$ 出发，走到正交化与奇异值分解



定义

给定矩阵A的形状为 $m \times p$ ，A的格拉姆矩阵为

$$G = A^T A$$

- A有m行、p列；A的格拉姆矩阵G形状为 $p \times p$
- 格拉姆矩阵的每个元素，本质上都是A的两个列向量的内积

图 1 • 矩阵A的格拉姆矩阵 $A^T A$

- A的每一列 a_1 、 a_2 、...、 a_p ，经过ATA运算后压缩成 $p \times p$ 的内积表




图 1. 矩阵 A 的格拉姆矩阵 $A^T A$

格拉姆矩阵G为对称矩阵，且半正定

$$G^T = G, \quad x^T G x = \|Ax\|^2 \geq 0$$

- 对任意p维非零列向量x，二次型 $x^T G x$ 都可以写成 $\|Ax\|^2$ ，天然非负
- 本书第13章第1节会专门讲解正定性

格拉姆矩阵透露出A列向量的线性相关信息

- ① $\det(ATA)=0$ ，当且仅当矩阵A的列向量线性相关
- ② $\text{rank}(ATA)=\text{rank}(A)$ ——ATA只是对列向量间的内积关系做“压缩整理”，不增不减信息维度

用矩阵乘法第一视角展开ATA，就会看到内积

$$A^T A = [\langle a_1, a_1 \rangle \cdots \langle a_1, a_p \rangle; \vdots \ddots \vdots; \langle a_p, a_1 \rangle \cdots \langle a_p, a_p \rangle]$$

- 对角线元素为A列向量和自身内积： $a_j^T a_j = a_j \cdot a_j = \|a_j\|^2$
- 非对角线元素为A两两列向量内积： $a_i^T a_j = a_j^T a_i$ ，这也印证了ATA为对称矩阵

图 2、图 3 • 格拉姆矩阵 $A^T A$ 的对角线与非对角线元素

- 左：对角线元素 $a_1^T a_1 = \|a_1\|^2$ ；右：非对角线元素 $a_3^T a_1 = a_1^T a_3$ ，两两内积对称分布




图 2. 矩阵 A 的格拉姆矩阵的对角线元素




图 3. 矩阵 A 的格拉姆矩阵的非对角线元素

值得注意的是， AA^T 也是一个格拉姆矩阵

① AA^T 的主对角线为A行向量和自身的内积，即行向量L2范数的平方

② AA^T 的非主对角线元素为A两两行向量内积，显然 AA^T 也是对称矩阵

图 4 • 矩阵 A^T 的格拉姆矩阵 AA^T

- 同一个矩阵 A ，从列向量出发得到 AA^T ，从行向量出发得到 A^TA ——都是格拉姆矩阵




图 4. 矩阵 A^T 的格拉姆矩阵 AA^T

对 $G=AA^T$ 进行谱分解得到

$$G = V\Lambda V^T$$

- G 是实对称矩阵，谱分解结果 V 为正交矩阵， Λ 为对角方阵

图 5 • 对格拉姆矩阵 $A^T A$ 谱分解

- $p \times p$ 的 G 分解为 V 、 Λ 、 V^T 三个 $p \times p$ 矩阵的连乘




图 5. 对格拉姆矩阵 $A^T A$ 谱分解

G对角化得到

$$V^T G V = \Lambda$$

- 把V写成 $[v_1, v_2, \dots, v_p]$, $V^T G V$ 展开后第(i,j)元素为 $v_i^T G v_j$

图 6 • 格拉姆矩阵 $A^T A$ 对角化

- 对角化把 V 、 G 、 V^T 三者连乘，重新排布成一个干净的对角方阵 Λ




图 6. 格拉姆矩阵 $A^T A$ 对角化

把 $G = ATA$ 代入并展开

整理后得到一组等式

$$(Av_i)^T(Av_j) = \lambda_j \quad (i=j), \quad (Av_i)^T(Av_j) = 0 \quad (i \neq j)$$

- $v_i^T G v_j = v_i^T A T A v_j = (Av_i)^T (Av_j)$: 主对角线 ($i=j$) 为 λ_j , 非主对角线 ($i \neq j$) 为 0

图 7、图 8 • 对角方阵 Λ 的主对角线与非主对角线元素

- 左: $v_1^T G v_1 = \lambda_1$ (主对角线) ; 右: $v_3^T G v_1 = 0$ (非主对角线, 两个不同特征向量之间)




图 7. 对角方阵 Λ 主对角线元素




图 8. 对角方阵 Λ 非主对角线元素

令 $\mathbf{b}_j = \mathbf{A}\mathbf{v}_j$ ($j=1, \dots, p$), 上式可以写成

$$\mathbf{B}^T \mathbf{B} = \mathbf{A}$$

- 由于 $\mathbf{v}_j$ 是单位列向量, 矩阵乘积 $\mathbf{A}\mathbf{v}_j$ 相当于矩阵 $\mathbf{A}$ 向 $\text{span}(\mathbf{v}_j)$ 投影结果为 $\mathbf{b}_j$
- 矩阵 $\mathbf{A}$ 的每个行向量相当于一个数据点

图 9、图 10 • 矩阵A向span(vj)投影结果为bj

- 左：一般情形 $A@v_j=b_j$ ；右：具体例子A向span(v1)投影结果为b1




图 9. 矩阵 A 向 $\text{span}(v_j)$ 投影结果为 b_j




图 10. 矩阵 A 向 $\text{span}(v_1)$ 投影结果为 b_1

矩阵乘法 $B=AV$ ，几何角度看， A 向 $\text{span}(v_1, v_2, \dots, v_p)$ 投影结果为 B

$$B = AV$$

- 本书前文介绍的QR分解也是正交化，请大家回顾对比

图 11 • 矩阵A向 $\text{span}(\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_p)$ 投影结果为B

- A的每一列同时向p个特征向量方向投影，拼成新矩阵B




图 11. 矩阵 A 向 $\text{span}(\mathbf{v}_1, \mathbf{v}_1, \dots, \mathbf{v}_p)$ 投影结果为 B

将 $B=AV$ 带入 BTB ，得到的结果正是 Λ

$$B^TB = (AV)^T(AV) = V^TA^TAV = V^TGV = \Lambda$$

- 大家是否发现，B的列向量两两正交？！ $B=AV$ 相当于完成了矩阵A的正交化

图 12 • 矩阵B的格拉姆矩阵 $B^T B$

- $B^T B = \Lambda$ 是对角方阵，说明B的列向量两两正交




图 12. 矩阵 B 的格拉姆矩阵 $B^T B$

图 13、图 14 • B的格拉姆矩阵的对角线与非对角线元素

- 对角线元素 $\|b_j\|^2 = \lambda_j$ ；非对角线元素恒为0——这正是“正交”的代数含义




图 13. 矩阵 B 的格拉姆矩阵的对角线元素




图 14. 矩阵 B 的格拉姆矩阵的非对角线元素

图 15 • A 向 $\text{span}(v_j)$ 正交投影结果为 b_j ，几何视角

- A 的每个行向量 $a^{(i)}$ 是一个散点；散点向 $\text{span}(v_j)$ 投影，落点到原点的距离就是 $b_j^{(i)}$




图 15. A 向 $\text{span}(v_j)$ 正交投影结果为 b_j ，几何视角

$\|b_j\|^2$ 代表 $b_j(i)$ 到原点距离（有正负）的平方和

$$\|b_j\|^2 = (b_j^{(1)})^2 + (b_j^{(2)})^2 + \dots = \lambda_j$$

- 若 λ_j 按大小排列, $\lambda_1 \geq \lambda_2 \geq \dots$, 说明特征向量 v_j 也有主次之分
- 图15中的椭圆实际上是马氏距离——本书第13章第4节会详细讲解

图 16 • 特征值、 s_j (特征值平方根) 决定了特征向量的“解释力”大小

- A朝第一特征向量 v_1 投影对应的 $\|b_1\|^2$ 最大, 这正是第12章主成分分析的核心思路




图 16. 特征值、 s_j (特征值平方根) 决定了特征向量的“解释力”大小

开方后对 b_j 单位化，为“层层叠加”做准备

① 开方： $\|b_j\| = \sqrt{\lambda_j}$ ，记作 s_j ，则 $\|b_j\| = s_j$

② 单位化：若 $\lambda_j > 0$ ，令 $u_j = b_j/s_j$ ，即 $b_j = s_j u_j$

③ 代入 $b_j = Av_j$ ，得到 $Av_j = s_j u_j$ ——这是矩阵 A 、特征向量 v_j 、单位向量 u_j 之间的桥梁

由于V为正交矩阵，矩阵A可以写成若干秩一矩阵的叠加

$$A = Av_1v_1^T + Av_2v_2^T + \dots = s_1u_1v_1^T + s_2u_2v_2^T + \dots$$

- $v_jv_j^T$ 都是投影矩阵； s_j （特征值平方根）决定了对应特征向量的“解释力”大小

图 17 • 层层叠加

- p 个形状相同的秩一矩阵 $Av_jv_j^T$ 依次相加，正好还原出矩阵 A




图 17. 层层叠加

把一系列乘法 $Av_j = s_j u_j$ ($j=1, \dots, p$) 写成矩阵形式

$$AV = US$$

- U 的列向量为 $u_1, \dots, u_p$; S 为对角方阵, 主对角线元素为 $s_1, \dots, s_p$

$$AV = US$$

图 18 • $AV = US$

- A 右乘 V ，恰好等于 U 右乘对角方阵 S ——一系列投影关系被整理成一个矩阵等式




图 18. $AV = US$

由于V为正交矩阵，V的逆等于其转置

整理 $AV=US$ ，得到

$$A = USV^T$$

- 这正是本书第14章要讲解的奇异值分解（SVD）；S的主对角线元素就是奇异值

图 19 • 矩阵A的SVD分解

- 大家很快会发现，矩阵U的列向量也均为单位向量，且两两正交




图 19. 矩阵 A 的 SVD 分解

格拉姆矩阵串起了本书的多条主线

① 格拉姆矩阵 $G=AA^T$ 永远对称、半正定，元素即列向量内积

② 谱分解 $G=V\Lambda V^T$ ，对角化后每个 λ_j 对应一个投影方向的“解释力”

③ $B=AV$ 完成正交化，是QR分解之外的又一条正交化路径

④ 层层叠加 $A=\sum s_j u_j v_j^T$ ，直接推导出 $A=USV^T$ ，即奇异值分解

⑤ 实践中最常见的格拉姆矩阵——协方差矩阵，将是下一章的主角

本节关键词

格拉姆矩阵 Gram Matrix, $G=ATA$, 元素为A列向量两两内积

L2范数平方 格拉姆矩阵对角线元素, 即列向量自身内积

投影 $b_j = Av_j$ A向 $\text{span}(v_j)$ 投影的结果, 长度平方等于 λ_j

解释力 特征值 λ_j (或 s_j) 越大, 对应特征向量方向包含的信息越多

奇异值分解SVD $A=USVT$, S主对角线元素为奇异值, U、V均为正交矩阵

半正定 对任意非零x, $xTGx = \|Ax\|^2 \geq 0$

谱分解 $G=V\Lambda VT$, 实对称矩阵G的特征值分解

正交化 $B=AV$ A向V的列空间投影后得到列向量两两正交的B

层层叠加 $A=\sum s_j u_j v_j^T$, 将A拆解为p个秩一矩阵之和

协方差矩阵 实践中最常见的格拉姆矩阵之一, 下一章详解

延伸阅读

延伸阅读

复习 · 11.2 谱分解

格拉姆矩阵的谱分解正是对实对称矩阵谱分解的直接应用

延伸阅读 · 12.1 数据矩阵

下一章将介绍协方差矩阵——最常见的格拉姆矩阵

预告 · 14.1 奇异值分解

本节层层叠加的推导，正是SVD最直观的入门路径

开源代码仓库

全书代码、图片：<https://github.com/Visualize-ML>

习题 Q1 – Q9

Q1a 请计算矩阵 $\begin{bmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{bmatrix}$ 的格拉姆矩阵 ATA 。

Q2 对Q1中两个格拉姆矩阵分别谱分解，写出 V 、 Λ ，并验证 $G=V\Lambda V^T$ 。

Q4 证明：对任意非零向量 x ， $x^TATAx=||Ax||^2\geq 0$ ，即 ATA 半正定。

Q6 解释为什么 $\det(ATA)=0$ 当且仅当 A 的列向量线性相关，并用一个具体例子验证。

Q8 分别计算Q1两个矩阵的 AAT ，比较 AAT 与 ATA 的形状、迹是否相同。

Q1b 请计算矩阵 $\begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix}$ 的格拉姆矩阵 ATA 。

Q3 证明：对任意矩阵 A ，格拉姆矩阵 ATA 一定是对称矩阵。

Q5 用Python编写函数`gram(A)`，返回 ATA ，并在Q1的两个矩阵上验证结果。

Q7 证明： $\text{rank}(ATA)=\text{rank}(A)$ ，并用Q1中的矩阵验证秩是否相等。

习题 Q10 – Q18

Q10 用`numpy.linalg.eigh`对Q1中格拉姆矩阵求谱分解，并与手算结果比较。

Q12 用Python验证 $B=AV$ ，并输出 BTB ，确认非对角线元素接近0。

Q14 对Q1中的矩阵，计算 $s_j = \sqrt{\lambda_j}$ ，并对 b_j 单位化得到 u_j 。

Q16 把 A 写成 $\sum s_j u_j v_j^T$ 的层层叠加形式，并用Python验证求和结果等于原矩阵 A 。

Q18 用matplotlib可视化图15的几何视角，画出散点、投影方向与投影结果。

Q11 写出 $B=AV$ 的定义，并证明 B 的列向量两两正交（即 BTB 为对角阵）。

Q13 解释 $\|b_j\|^2 = \lambda_j$ 的几何含义，并用Q1中的矩阵计算 b_j 和 λ_j 验证。

Q15 验证 $Av_j = s_j u_j$ 对Q1中的矩阵是否成立，用Python逐项核对。

Q17 解释为什么 $v_j v_j^T$ 是投影矩阵，并验证它满足幂等性（ $v_j v_j^T)^2 = v_j v_j^T$ 。

习题 Q19 – Q25

Q19 把 $AV=US$ 写成矩阵形式，并用Python验证US确实等于AV。

Q21 用`numpy.linalg.svd`对Q1中的矩阵求SVD，比较S的对角线元素与本节sj是否一致。

Q23 探索：格拉姆矩阵 ATA 和 AAT 的非零特征值是否相同？用Q1的矩阵验证。

Q25 预告：下一节将讨论非对称方阵EVD之外更多分解，猜一猜Cholesky分解和格拉姆矩阵有什么关系？

Q20 推导 $A=USVT$ ，并解释为什么这一步需要V是正交矩阵。

Q22 验证U的列向量是否为单位向量，且两两正交（即 $UTU=I$ ）。

Q24 解释为什么协方差矩阵也是一种格拉姆矩阵，它对应哪个原始矩阵？

10个和AI互动的Prompt

- 1 解释什么是格拉姆矩阵，以及为什么它一定是对称且半正定的。
- 2 解释格拉姆矩阵的对角线、非对角线元素分别代表什么几何含义。
- 3 解释 ATA 和 AAT 的关系与区别，它们的非零特征值有何联系。
- 4 解释格拉姆矩阵的谱分解 $G=V\Lambda V^T$ 中， V 和 Λ 分别代表什么。
- 5 解释 $B=AV$ 为什么能够完成矩阵 A 的正交化，和QR分解有何异同。

10个和AI互动的Prompt






- 6 解释为什么 $\|b_j\|^2$ 恰好等于特征值 λ_j ，并说明这背后的几何意义。
- 7 解释特征值大小如何决定特征向量的“解释力”，与主成分分析有何关系。
- 8 解释如何把矩阵A写成 $s_1u_1v_1^T + s_2u_2v_2^T + \dots$ 的层层叠加形式。
- 9 推导从 $AV=US$ 到 $A=USVT$ 的完整过程，并解释这就是奇异值分解。
- 10 用Python演示如何从格拉姆矩阵的谱分解出发，一步步推导出SVD。

数学

数学基础

线性代数


概率统计



Python编程

数据可视化

工具



数据分析
图和网络

回归、降维
分类、聚类

实践