

14 奇异值分解

14.1 奇异值分解

任意形状的实数矩阵都能分解为旋转、缩放、再旋转，揭示矩阵背后的内在结构



鸢尾花书·《线性代数不难》 | 开源代码与书稿: <https://github.com/Visualize-ML>

本节你将掌握的核心技能

1 任意形状实矩阵都能完成奇异值分解

2 完全型奇异值分解中， U 与 V 都是正交矩阵


3 U 与 V 表示各自空间的一组规范正交基，可视为旋转操作

4 S 是对角矩阵，主对角线是奇异值

5 矩阵秩等于非零奇异值的个数

6 通过求解两个格拉姆矩阵的特征值和特征向量，可重建SVD分解过程

旋转 → 缩放 → 再旋转



从多个角度理解奇异值分解

- ① 代数视角: $X = USV^T$, 任何形状的实矩阵都能完成SVD
- ② 正交视角: U、V都是正交矩阵, 可视为空间旋转
- ③ 缩放视角: S是对角矩阵, 主对角线的奇异值代表缩放效果
- ④ 秩视角: 矩阵的秩等于非零奇异值的个数
- ⑤ 分解视角: 谱分解 XX^T 的转置得到U, 谱分解 $X^T X$ 的转置得到V
- ⑥ 计算视角: 手解SVD的关键是谱分解两个格拉姆矩阵

给定任意实数矩阵X，经过完全型奇异值分解得到

$$X_{n \times D} = U_{n \times n} S_{n \times D} V^T_{D \times D}$$

- U为左奇异向量矩阵，为正交矩阵，列向量张成 $\mathbb{R}^n$ 空间的规范正交基
- S为对角矩阵，主对角线元素为奇异值；V为右奇异向量矩阵，为正交矩阵

图1 • 完全型SVD分解的热图

- $X=U@S@V^T$ 的转置：U、S、V的颜色格子直观展示了分解后各部分的数值





图 1. 完全型 SVD 分解

图2 · 四种SVD分解类型

- 完全型之外，还有经济型、紧凑型、截断型SVD，本章后续将逐一展开



S: 主对角线元素为奇异值

奇异值一般按从大到小排列

$$s_1 \geq s_2 \geq \dots \geq s_D > 0$$

- 若X列满秩，奇异值均大于0；若X列不满秩（秩为r），则有D-r个奇异值为0
- 也就是说，矩阵秩等于非零奇异值的个数

图3 • 完全型SVD分解，X列不满秩

- 把X的最后两列替换成前两列后，X列不满秩，图中出现两个奇异值为0




图 3. 完全型 SVD 分解，X 列不满秩

U: 左奇异向量矩阵

完全型SVD中，左奇异向量矩阵U是正交矩阵

$$U^T @ U = U @ U^T = I$$

- U的列向量、行向量都是单位向量，且两两正交
- 从几何角度看，正交矩阵U可以看作是在n维空间的旋转

图4 • U列向量均为单位向量，且两两正交

- U的转置乘以U等于单位矩阵I，图中对角线全为1，其余全为0




图 4. U 列向量均为单位向量，且两两正交

图5 • U行向量均为单位向量，且两两正交

- U乘以U的转置同样等于单位矩阵I，说明行向量也两两正交




图 5. U 行向量均为单位向量，且两两正交

XX的转置相当于矩阵X转置的格拉姆矩阵

$$XX^T = USS^TU^T$$

- 格拉姆矩阵为对称矩阵，且半正定或正定，因此上式就是一个谱分解
- 展开后可以发现，XX的转置的特征值中有大量的0

图6 • 计算格拉姆矩阵 XX 的转置

- XX 的转置 = $X @ X$ 的转置，结果为 $n \times n$ 的对称矩阵




图 6. 计算格拉姆矩阵 XX^T

图7 • XX^T 的转置的特征值分解，X列满秩

- 若X列满秩，X的奇异值均非0，这样 XX^T 的转置有 $n-D$ 个特征值为0




图 7. XX^T 的特征值分解，X 列满秩

图8 • XX^T 的转置的特征值分解，X列不满秩

- 若X列不满秩（秩为r），这样 XX 的转置有n-r个特征值为0




图 8. XX^T 的特征值分解，X 列不满秩

V: 右奇异向量矩阵

完全型SVD中，右奇异向量矩阵V是正交矩阵

$$V^T @ V = V @ V^T = I$$

- 从几何角度看，正交矩阵V可以看作是在D维空间的旋转
- 注意，一般来说U、V是不同空间的旋转

图9 • 右奇异向量矩阵V为正交矩阵

- V的转置乘以V、V乘以V的转置都等于单位矩阵I




图 9. 右奇异向量矩阵 V 为正交矩阵

X转置X相当于矩阵X的格拉姆矩阵

$$X^T X = V S^T S V^T$$

- 这也是一个谱分解，本书前文介绍格拉姆矩阵时聊过这个谱分解
- 比较两个格拉姆矩阵，可以发现它们有相同的非零特征值

图10 • 计算格拉姆矩阵 X 转置 X

- X 转置 $X = X$ 的转置 $@$ X , 结果为 $D \times D$ 的对称矩阵




图 10. 计算格拉姆矩阵 $X^T X$

图11 • X转置X的特征值分解，X列满秩

- 若X列满秩，则X转置X的特征值均非0



图 11. $X^T X$ 的特征值分解， X 列满秩

图12 • X转置X的特征值分解，X列不满秩

- 若X列不满秩（秩为 r ），这样X转置X有 $D-r$ 个特征值为0



图 12. $X^T X$ 的特征值分解， X 列不满秩

给定细高矩阵A，计算第一个格拉姆矩阵A转置A

$$A = [0,1; 1,1; 1,0] , \quad A^T A = [2,1; 1,2]$$

- 图7和图11给了我们手解奇异值分解的思路——谱分解两个格拉姆矩阵

求解V

A转置A的特征值和特征向量

$$\lambda_1 = 3, \quad \mathbf{v}_1 = [\sqrt{2}/2; \sqrt{2}/2], \quad \lambda_2 = 1, \quad \mathbf{v}_2 = [-\sqrt{2}/2; \sqrt{2}/2]$$

- 有关手解特征值分解，请大家回顾本书第11章第1节

计算第二个格拉姆矩阵AA的转置

$$AA^T = [1, 1, 0; 1, 2, 1; 0, 1, 1]$$

- 注意区分，A转置A形状为 2×2 ，AA的转置形状为 3×3

AA的转置的特征值和特征向量（一）

$$\lambda_1 = 3, \quad \mathbf{u}_1 = [1/\sqrt{6}; 2/\sqrt{6}; 1/\sqrt{6}]$$

- λ_1 、 λ_2 在A转置A和AA的转置中都出现过，这不是巧合

AA的转置的特征值和特征向量（二）

$$\lambda_2 = 1, \quad \mathbf{u}_2 = [\sqrt{2}/2; 0; -\sqrt{2}/2], \quad \lambda_3 = 0, \quad \mathbf{u}_3 = [\sqrt{3}/3; -\sqrt{3}/3; \sqrt{3}/3]$$

- $\lambda_3=0$ 对应的 $\mathbf{u}_3$ ，正是AA的转置中多出来的那一个特征值

奇异值矩阵S的对角线元素为特征值的平方根

$$S = [\sqrt{\lambda_1}, 0; 0, \sqrt{\lambda_2}; 0, 0] = [\sqrt{3}, 0; 0, 1; 0, 0]$$

- 奇异值矩阵S对角线元素为 λ_1 和 λ_2 的平方根，这是特征值分解和SVD分解的重要区别与联系

矩阵A的完全型SVD分解结果

$$A = USV^T = \begin{bmatrix} 1/\sqrt{6}, \sqrt{2}/2, \sqrt{3}/3; 2/\sqrt{6}, 0, -\sqrt{3}/3; 1/\sqrt{6}, -\sqrt{2}/2, \sqrt{3}/3 \end{bmatrix} \begin{bmatrix} \sqrt{3}, 0; 0, 1; 0, 0 \end{bmatrix} \begin{bmatrix} \sqrt{2}/2, \sqrt{2}/2; -\sqrt{2}/2, \sqrt{2}/2 \end{bmatrix}^T$$

- 手解SVD不是学习目的，重点是理解SVD背后的数学思想与多种视角

奇异值分解还能做什么

- ① 数据压缩：保留最大的若干个奇异值，即可近似还原原矩阵
- ② 特征提取：奇异值大小反映数据中不同方向的重要程度
- ③ 推荐系统：矩阵分解技术常以SVD为基础
- ④ 图像处理：低秩近似可用于图像压缩与去噪
- ⑤ 自然语言处理：潜在语义分析(LSA)利用SVD挖掘词与文档的潜在结构
- ⑥ 数值计算：求解矩阵的伪逆、条件数都离不开SVD

表 • 格拉姆矩阵 XX 的转置与 X 转置 X 对比

对比维度	格拉姆矩阵 XX 的转置	格拉姆矩阵 X 转置 X
矩阵形状	$n \times n$	$D \times D$
对应的奇异向量	U (左奇异向量矩阵)	V (右奇异向量矩阵)
特征值与奇异值的关系	特征值等于奇异值的平方	特征值等于奇异值的平方
X 列满秩时, 非零特征值个数	D 个	D 个 (全部非零)
X 列满秩时, 为0的特征值个数	$n - D$ 个	0个

小结

完全型SVD的核心要点

任意形状的实数矩阵X都能分解为 $X = USV^T$

U、V都是正交矩阵，可视为空间旋转；S为对角矩阵，主对角线是奇异值

矩阵的秩等于非零奇异值的个数

谱分解 XX^T 的转置得到U与S的平方，谱分解 X^TX 得到V与S的平方

手解SVD的关键是谱分解两个格拉姆矩阵，重建U、S、V

本节关键术语

奇异值分解 *SVD* —— $X=USV^T$ ，任意形状实矩阵都能完成的通用分解

左奇异向量矩阵 U —— 正交矩阵，列向量张成 $\mathbb{R}^n$ 空间的规范正交基

格拉姆矩阵 *Gram Matrix* —— XX^T 或 $X^T X$ ，对称且半正定或正定

矩阵的秩 *Rank* —— 等于矩阵非零奇异值的个数

完全型SVD *Full SVD* —— U 、 V 均为完全正交方阵的SVD形式

奇异值 *Singular Value* —— S 对角线元素，代表各维度的缩放效果

右奇异向量矩阵 V —— 正交矩阵，列向量张成 $\mathbb{R}^p$ 空间的规范正交基

谱分解 *Spectral Decomposition* —— 实对称矩阵的特征值分解

正交矩阵 *Orthogonal Matrix* —— 转置乘以自身等于单位矩阵，几何上代表旋转

经济型SVD *Economy SVD* —— 预告内容， U 为半正交矩阵，下节展开

延伸阅读

预告 · 14.2 几何角度看SVD

本书第14章 从几何变换角度理解U、S、V

回顾 · 11.1 特征值分解

本书第11章 手解特征值分解的方法

回顾 · 格拉姆矩阵与谱分解

本书前文 格拉姆矩阵的定义、性质与谱分解

开源仓库

全书代码与图像素材: <https://github.com/Visualize-ML>

习题 Q1 – Q9

Q1 请手解矩阵 $A = \begin{bmatrix} 0 & -1 \\ -1 & -1 \\ -1 & 0 \end{bmatrix}$ 的奇异值分解，并用Python验证结果。

Q3 请手解矩阵 $A = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$ 的奇异值分解，并用Python验证结果。

Q5 请用`numpy.linalg.svd()`计算本节例子中细高矩阵 $A = \begin{bmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{bmatrix}$ 的SVD，并与手工计算结果比较。

Q7 请证明：任意实矩阵 X 的奇异值都是非负实数。

Q9 探索：如果矩阵 X 是方阵且对称，SVD分解与谱分解有什么关系？

Q2 请手解矩阵 $A = \begin{bmatrix} 5/4 & -3/4 \\ -3/4 & 5/4 \end{bmatrix}$ 的奇异值分解，并用Python验证结果。

Q4 请手解矩阵 $A = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 1 & 0 \end{bmatrix}$ 的奇异值分解，并用Python验证结果。

Q6 请验证本节例子中 A 的奇异值 $s_1 = \sqrt{3}$ 、 $s_2 = 1$ ，是否等于 A 转置 A 特征值的平方根。

Q8 请解释为什么 XX 的转置与 X 转置 X 有相同的非零特征值。

习题 Q10 – Q17

Q10 请用Python验证：正交矩阵U满足U的转置乘以U等于单位矩阵。

Q12 请证明：矩阵X的秩等于其非零奇异值的个数。

Q14 请用Python函数实现手解SVD的思路：谱分解两个格拉姆矩阵，重建U、S、V。

Q16 请计算一个 4×3 矩阵的SVD，并验证U、V都是正交矩阵。

Q11 探索：为什么完全型SVD中的U、V可以看作是空间的旋转？请结合行列式取值讨论。

Q13 探索：如果矩阵X的列不满秩，图3中显示有两个奇异值为0，这对应X的哪些几何性质？

Q15 探索：奇异值分解和特征值分解有什么区别？哪些矩阵既能做特征值分解也能做SVD？

Q17 探索：奇异值的大小和矩阵的“重要方向”有什么关系？

习题 Q18 – Q25

Q18 用matplotlib可视化本节例子中矩阵A对单位圆的线性变换效果，并标出奇异值方向。

Q20 探索：SVD分解与主成分分析(PCA)有什么联系？

Q22 探索：为什么本节说“任何形状的实数矩阵都可以完成奇异值分解”，而特征值分解只适用于方阵？

Q24 探索：奇异值分解与本书前文的Cholesky分解、LDL分解，在应用场景上有什么不同？

Q19 探索：SVD分解在数据压缩中如何应用？请查阅相关资料并简述原理。

Q21 证明：如果X是正交矩阵，则X的所有奇异值都等于1。

Q23 用Python比较：对同一个矩阵分别计算特征值分解（如果存在）和SVD分解，两者的差异体现在哪里？

Q25 预习思考：下一节将从几何角度理解SVD，你认为U、S、V各自对应怎样的几何操作？

10个可以和AI互动的Prompt

1 请解释为什么任意形状的实数矩阵都能完成奇异值分解，而特征值分解只适用于方阵。

2 请解释完全型SVD中U、S、V各自的含义，以及它们的矩阵形状。

3 请解释为什么正交矩阵可以看作是空间的旋转。

4 请解释矩阵的秩为什么等于非零奇异值的个数。

5 请用Python演示如何用`numpy.linalg.svd()`对一个矩阵做奇异值分解。

10个可以和AI互动的Prompt

6 请解释 XX 的转置和 X 转置 X 这两个格拉姆矩阵在SVD中各自的作用。

7 请解释为什么奇异值矩阵 S 的对角线元素是格拉姆矩阵特征值的平方根。

8 请解释手解奇异值分解的完整流程，从格拉姆矩阵到 U 、 S 、 V 。

9 请解释奇异值分解与本书前文谱分解之间的联系与区别。




10 请解释奇异值分解在数据压缩或特征提取中可能的应用场景。

数学

数学基础

线性代数

概率统计



Python编程

数据可视化

工具

数据分析
图和网络

回归、降维
分类、聚类

实践

