

14 奇异值分解

14.4 截断型奇异值分解

把数据矩阵拆成秩一矩阵之和，用前 p 个主成分近似还原原始数据——从鸢尾花照片看懂低秩压缩



鸢尾花书 · 《线性代数不难》 | 开源代码与书稿: <https://github.com/Visualize-ML>

本节你将掌握的核心技能

1 截断型SVD：保留主成分，舍弃噪声和冗余信息

2 将数据矩阵分解为多个秩一矩阵的叠加

3 载荷 = 特征向量，得分 = 投影坐标

4 低秩近似还原原始数据：前 p 个主成分高效还原数据且压缩存储

5 X 在原空间不正交，但向 V 投影的结果 Z 完成正交化

从秩一叠加到低秩近似，再到正交投影




图 1 • 矩阵乘法第二视角展开经济型SVD分解

- 经济型SVD $X_{n \times D} = U_{n \times D} S_{D \times D} V_{D \times D}^T$ 按列展开, 得到 $X = s_1 u_1 v_1^T + s_2 u_2 v_2^T + \dots + s_D u_D v_D^T = \sum_j s_j u_j v_j^T$




图 2 • 原始数据相当于由D个形状相同矩阵求和的结果

- 每一层 $s_j \mathbf{u}_j \mathbf{v}_j^T$ 都是与 X 形状相同的秩一矩阵， D 层叠加还原出完整的 X




图 2. 原始数据相当于由 D 个形状相同矩阵求和的结果

图 3 • 前两个主成分还原部分原始数据

- u_i 、 v_i 都是单位向量，方向之间没有大小区别；奇异值 s_1 、 s_2 较大，对应方向对原始数据的贡献也更大




图 3. 前两个主成分还原部分原始数据

图 4 • 最后两个主成分还原部分原始数据

- 最后两层 $s_{D-1} u_{D-1} v_{D-1}^T$ 、 $s_D u_D v_D^T$ 对应的奇异值很小，贡献的色差也几乎难以察觉




图 4. 最后两个主成分还原部分原始数据

载荷 = 特征向量，得分 = 投影坐标

- ① 若奇异值 $s_1, s_2, \dots, s_D$ 从大到小排列， $\mathbf{v}_1$ 就是第一主成分载荷（loading）， $\mathbf{u}_1$ 就是第一主成分因子得分（score）
- ② 对角方阵 $\mathbf{S}$ 的主对角线元素，既可看作缩放 $\mathbf{U}$ 的列向量，也可看作缩放 $\mathbf{V}$ 的行向量
- ③ 注意，有些文献把载荷定义为“特征向量 $\times$ 奇异值”，与本节定义不同，使用时请留意
- ④ 不同Python函数完成SVD分解，结果单位向量的符号可能不同； $\mathbf{u}_j$ 、 $\mathbf{v}_j$ 同时变号不影响 $s_j \mathbf{u}_j \mathbf{v}_j^T$ 的结果

图 5 • 用前p个主成分还原原始数据

- $X_{n \times D} \approx \hat{X}_{n \times D} = U_{n \times p} S_{p \times p} (V_{D \times p})^T = s_1 u_1 v_1^T + \dots + s_p u_p v_p^T$; 只要前 p 个 s_j 都大于 0, X 的秩就是 p




图 5. 用前 p 个主成分还原原始数据

图 6 • 原始数据向V投影

- $XV = US$, 把等式两侧展开得到 $Xv_j = s_j u_j$, 相当于把 X 投影到 V 空间中




图 6. 原始数据向 V 投影

图 7 • 原始数据向 v_1 标量投影

- $Xv_1 = s_1 u_1$; 由于 $\|u_1\|=1$, 投影结果的模 $\|Xv_1\| = s_1$, 即奇异值就是投影长度




图 8 • X 向规范正交基 V 投影

- 数据矩阵 X 向规范正交基 $V=[v_1, v_2, \dots, v_D]$ 构成的 D 维空间投影, 写成 $Z = XV$




图 8. X 向规范正交基 V 投影

图 9 • 第二条计算Z的路径

- 由 $X = USV^T$ 代入得 $Z = USV^T V = US$; u_i 是“单位化”的投影坐标, s_i 是投影向量的模




图 9. 第二条计算 Z 的路径

图 10 • Z的格拉姆矩阵

- $Z^T Z = (US)^T US = S^T S$ 是对角阵，说明Z的列向量两两正交——X→Z完成的正是正交化




图 10. Z 的格拉姆矩阵

图 11 · 鸢尾花图片，经过黑白处理

- 作者拍摄的鸢尾花照片经过黑白化处理，每个像素都是 $[0,1]$ 范围内的数字，整幅图片可以看成是一个数据矩阵




图 11. 鸢尾花图片，经过黑白处理，来自《机器学习》

图 12 · 奇异值随主成分变化

- 对图片矩阵做SVD分解，前10个奇异值贡献最大，主导了图像的数据结构，之后迅速衰减




图 12. 奇异值随主成分变化，来自《机器学习》

图 13 · 利用第1、2、3、4主元还原鸢尾花照片

- 仅用前4个主成分还原，图像中只能看到大块“格子”，还看不出鸢尾花的样子




图 13. 利用第 1、2、3、4 主元还原鸢尾花照片

图 14 · 前4个秩一矩阵叠加

- 图13的还原结果相当于 $s_1 \mathbf{u}_1 \mathbf{v}_1^T$ 、 $s_2 \mathbf{u}_2 \mathbf{v}_2^T$ 、 $s_3 \mathbf{u}_3 \mathbf{v}_3^T$ 、 $s_4 \mathbf{u}_4 \mathbf{v}_4^T$ 这4个秩一矩阵叠加而成




图 14. 前 4 个秩一矩阵叠加

图 15 · 利用前64个主元还原鸢尾花照片

- 保留前64个主成分，图像已经清晰可辨；相比原图片，数据仅保留了约2.5%（64/2714），压缩效果显著




图 15. 利用前 64 个主元还原鸢尾花照片

截断型SVD：秩一叠加、近似还原、正交投影三条线索

① 经济型SVD可按列展开为 D 个秩一矩阵之和： $\mathbf{X} = \sum_j s_j \mathbf{u}_j \mathbf{v}_j^T$

② 奇异值 s_j 体现方向重要性，从大到小排列时 $\mathbf{v}_1$ 是第一主成分载荷， $\mathbf{u}_1$ 是第一主成分得分

③ 截断型SVD只保留前 p 个主成分： $\mathbf{X} \approx \mathbf{U}_{n \times p} \mathbf{S}_{p \times p} (\mathbf{V}_{D \times p})^T$ ，是对 $\mathbf{X}$ 的近似而非精确还原

④ 误差矩阵 $\mathbf{X}_{\text{error}}$ 也是若干层 $s_j \mathbf{u}_j \mathbf{v}_j^T$ 的叠加，由被舍弃的 $p+1$ 到 D 层构成

⑤ 正交投影视角： $\mathbf{Z} = \mathbf{XV} = \mathbf{US}$ ， $\mathbf{u}_j$ 是“单位化”的投影坐标， s_j 是投影长度

⑥ $\mathbf{Z}$ 的格拉姆矩阵 $\mathbf{Z}^T \mathbf{Z}$ 为对角阵，说明 $\mathbf{X}$ 到 $\mathbf{Z}$ 完成了正交化

本节关键词

秩一矩阵 形如 $s_j u_j v_j^T$ 的矩阵，秩恒为1，是SVD分解的基本构件

得分 Score 第 j 个主成分对应的投影坐标 u_j ，即因子得分

格拉姆矩阵 $Z^T Z$ ，用于检验 Z 的列向量是否两两正交

载荷 Loading 第 j 个主成分对应的方向向量 v_j ，即特征向量

截断型SVD 只保留前 p 个最大奇异值对应的成分，是对原矩阵的近似 ($\approx$)

正交化 X 向 V 投影得到 Z 的过程， Z 的列向量两两正交

延伸阅读

复习 · 第3章第2节 矩阵乘法第二视角

把矩阵乘法展开为向量外积之和，是本节推导的基础

复习 · 第11章第4节 格拉姆矩阵谱分解

理解 $Z^T Z$ 为对角阵背后的正交化逻辑

复习 · 14.1 – 14.3节 四种SVD分解

完全型、经济型、紧凑型SVD是理解截断型SVD的基础

开源代码仓库

全书代码、图片: <https://github.com/Visualize-ML>

习题 Q1 – Q9

Q1 请对矩阵 $A = \begin{bmatrix} 0 & 1 \\ 1 & 1 \\ 1 & 0 \end{bmatrix}$ 完成经济型奇异值分解，然后保留第一主成分近似还原原始矩阵，并计算误差。

Q3 对Q1中的矩阵A，分别写出 v_1 、 u_1 对应的载荷与得分，并说明它们各自的几何含义。

Q5 计算Q1矩阵A保留第一主成分后的误差矩阵Xerror，并验证 $Xerror = s_2 u_2 v_2^T$ 。

Q7 设计一个 4×3 矩阵，用Python完成经济型SVD，并绘制奇异值从大到小排列的柱状图。

Q9 解释为什么载荷 $\times$ 得分（ $v_j \times u_j$ 的外积再乘以 s_j ）得到的一定是秩一矩阵。

Q2 对Q1中的矩阵A，写出其秩一矩阵叠加形式，并用Python验证叠加结果等于原矩阵A。

Q4 用Python验证Q1矩阵A的两个秩一矩阵 $s_1 u_1 v_1^T$ 、 $s_2 u_2 v_2^T$ 之和恰好等于A。

Q6 用Python验证：向量 u_1 的L2范数为1，且 $\|A v_1\| = s_1$ 。

Q8 对Q7中的矩阵，分别用前1、2、3个主成分还原原始矩阵，比较还原误差的F范数变化。

习题 Q10 – Q17

Q10 用Python验证：数据矩阵 X 向规范正交基 V 投影得到的 Z ，其格拉姆矩阵 $Z^T Z$ 为对角阵。

Q12 解释为什么 u_j 可以被称为“单位化”的投影坐标，并用 $\|Xv_j\| = s_j \|u_j\| = s_j$ 加以说明。

Q14 用Q13中的图片，分别保留前4、16、64个主成分还原图片，比较视觉清晰度的变化。

Q16 用Matplotlib绘制Q14中 $p=4$ 时误差矩阵 X_{error} 的热图，参照图9的风格分析误差分布。

Q11 对Q7中的矩阵，计算 $Z = XV$ ，并验证 Z 的列向量两两正交。

Q13 用Python读入一张灰度图片，计算其奇异值，绘制奇异值随主成分变化的曲线，参照图12的风格。

Q15 计算Q14中 $p=64$ 时的压缩比（保留数据量/原始数据量），并与图15中64/2714的结果对比。

Q17 解释为什么不同Python函数求出的 u_j 、 v_j 符号可能相反，但 $s_j u_j v_j^T$ 的结果始终相同。

习题 Q18 – Q25

Q18 设计一个 5×4 矩阵，写出其经济型SVD展开为秩一矩阵之和的完整表达式。

Q20 用Python验证：截断型SVD的误差矩阵Xerror的F范数平方，等于被舍弃奇异值的平方和。

Q22 解释“有些文献把载荷定义为特征向量 $\times$ 奇异值”这种说法，并比较两种定义对应用的影响。

Q24 举一个截断型SVD在推荐系统或自然语言处理中的应用场景，并说明低秩近似的作用。

Q19 对Q18中的矩阵，分别计算保留 $p=1, 2, 3$ 个主成分的近似矩阵，并逐一验证其秩恰好为 p 。

Q21 结合第9章正交投影矩阵的内容，解释图8中 $Z=XV$ 这一投影操作的几何意义。

Q23 用Python分别计算一个满秩矩阵和一个亏秩矩阵的秩一分解，比较非零项数量的差异。

Q25 总结本节从“秩一叠加”“近似还原”“正交投影”三个视角理解截断型SVD的联系与区别。

10个和AI互动的Prompt

- 1 解释为什么经济型SVD可以展开写成D个秩一矩阵之和。
- 2 解释奇异值 s_j 的大小如何体现对应方向对原始数据的重要性。
- 3 解释“载荷=特征向量，得分=投影坐标”这句话的具体含义。
- 4 举例说明为什么截断型SVD得到的是近似而不是精确还原。
- 5 解释截断型SVD误差矩阵Xerror是如何由被舍弃的奇异值成分构成的。

10个和AI互动的Prompt


- 6 解释数据矩阵 X 向规范正交基 V 投影得到 Z 的几何意义。
- 7 解释为什么 Z 的格拉姆矩阵是对角阵，这说明了什么。
- 8 结合鸢尾花照片的例子，解释截断型SVD在图像压缩中的实际效果。
- 9 解释为什么不同Python函数求出的奇异向量符号可能不同，但不影响最终结果。
- 10 比较截断型SVD和主成分分析（PCA）之间的联系。

数学


数学基础

线性代数

概率统计



Python编程



数据可视化

工具



数据分析
图和网络

回归、降维
分类、聚类

实践

