

15 图论和网络



15.4 拉普拉斯矩阵和谱聚类

从邻接矩阵、度矩阵构造拉普拉斯矩阵，归一化后做特征值分解，用最小特征值对应的特征向量把人际网络分割成簇

鸢尾花书 · 《线性代数不难》 | 开源代码与书稿: <https://github.com/Visualize-ML>

本节你将掌握的核心技能

1

谱聚类的基本流程：从邻接矩阵、度矩阵，到拉普拉斯矩阵、归一化拉普拉斯矩阵，再到特征值分解

2

无权无向图邻接矩阵是对称矩阵，元素为1表示有连接，0表示无连接

3

无向图度矩阵是对角矩阵，对角线元素是节点的度数，反映节点的活跃程度

4

度数高的节点通常是社交网络的核心人物，度数低的节点往往处于边缘地位

5

拉普拉斯矩阵通过度矩阵减去邻接矩阵得到，体现图的连接结构

6

归一化处理可以消除节点度数差异，防止高连接节点主导聚类结果

7

选取最小特征值对应的特征向量，节点在低维空间中位置相近代表社交关系紧密

从邻接矩阵、度矩阵，到拉普拉斯矩阵，再到谱聚类




图 1 • 空手道俱乐部会员无向图

- 节点表示俱乐部成员，编号0~33；边表示两人是否经常一起训练或社交，这是研究网络结构的经典数据集Zachary's Karate Club（1977年提出）
- 由于俱乐部领导人之间的冲突，成员最终分裂成两个群体，这种分裂可以通过社区检测算法自动识别




图 1. 空手道俱乐部会员无向图

图 2 • 邻接矩阵A

- 根据图1节点间的连接关系计算得到邻接矩阵A；无向图的邻接矩阵A为对称矩阵
- 对于无权无向图，A元素为0表示两节点之间不存在边，为1表示存在一条边




图 2. 邻接矩阵

图 3 • 度矩阵D

- D是一个对角矩阵，每个对角线元素是对应节点的度数，即该节点连接的边的数量之和
- 可以直接用邻接矩阵A按行（或按列）求和得到度矩阵D的对角线元素




图 3. 度矩阵

图 4 • 各个节点的度

- 编号0、33节点度数特别高，相当于群体中的“核心人物”，与更多其他节点建立了直接联系
- 度数越低，意味着该节点在网络中联系越少，可能是边缘角色或处于结构上孤立的位置




图 4. 各个节点的度

图 5 • 根据度值渲染节点

- 用颜色深浅表示节点度数大小，度数反映了节点在网络中的直接影响力和参与程度
- 观察颜色分布，似乎已经能隐约看出两个“朋友圈”的雏形




图 5. 根据度值渲染节点

拉普拉斯矩阵通过度矩阵减去邻接矩阵得到

$$L = D - A$$

- 对于无向图，度矩阵D和邻接矩阵A都是对称矩阵，因此拉普拉斯矩阵L也是对称矩阵
- 拉普拉斯矩阵是图结构的重要表示，反映节点之间的连通关系；它的特征值、特征向量还能揭示网络内部的分区结构

图 6 • 拉普拉斯矩阵L

- L的主对角线元素就是各节点的度数（来自度矩阵D），非对角线元素是邻接矩阵A取相反数
- 拉普拉斯矩阵同时编码了节点的连接数量（对角线）和连接关系（非对角线）




图 6. 拉普拉斯矩阵

图 7 · 归一化拉普拉斯矩阵

- 在 L 两侧分别乘以度矩阵 D 的负二分之一次方，相当于对 L 的行、列分别做缩放，得到归一化拉普拉斯矩阵，其主对角线元素均为1
- 原始拉普拉斯矩阵在度数分布差异大的图中，容易让高连接节点主导整体结构；归一化处理后，每个节点的连接强度都被标准化，聚类结果更公平




图 7. 归一化拉普拉斯矩阵

对归一化拉普拉斯矩阵做特征值分解，即谱分解

$$L = V\Lambda V^T$$

- 归一化拉普拉斯矩阵是实对称矩阵，因此它的特征值分解就是谱分解， V 是正交矩阵， Λ 是特征值对角矩阵
- 把对应特征向量按特征值大小升序排列，为后续构造低维空间做准备

图 8 • 归一化拉普拉斯矩阵的特征值分解（谱分解）

- 依次展示 $L=V@A@V^T$ 四个矩阵， V 的列是特征向量， A 主对角线是对应的特征值
- 归一化拉普拉斯矩阵是实对称矩阵， V 是正交矩阵，满足 $V@V^T$ 等于单位矩阵




图 8. 归一化拉普拉斯矩阵的特征值分解 (谱分解)

图 9 • 特征值对角方阵 Λ

- 主对角线元素就是34个特征值，从左上到右下按升序排列
- 这些特征值全部非负，这是（归一化）拉普拉斯矩阵的一个重要性质




图 9. 特征值对角方阵

图 10 • 特征值递增排列

- 把34个特征值按从小到大排列，最小的几个特征值明显小于1，随后有一段特征值聚集在1附近，之后逐渐增大
- 谱聚类选取前几个最小特征值对应的特征向量，用来构造低维空间




图 10. 特征值递增排列

图 11 • 正交矩阵V

- V的每一列都是归一化拉普拉斯矩阵的一个特征向量，列与列之间两两正交
- 前两列v1、v2对应最小的两个特征值，将被用来构造二维空间表示每个节点




图 11. 正交矩阵 V

图 12 • 前两个特征向量构成的散点图

- 用 v_1 、 v_2 这两个特征向量的取值作为每个节点的新坐标，红色点纵轴坐标大于0，蓝色点纵轴坐标小于0
- 相互连接紧密的节点在这个低维空间中位置相近，连接稀疏的节点则相距较远——已经把34名成员分割成了两簇




图 12. 前两个特征向量构成的散点图

图 13 • 分割无向图

- 按图12中纵轴坐标的正负给节点染色，红色、蓝色分别代表谱聚类得到的两个簇
- 这个结果与Zachary记录的俱乐部真实分裂情况高度吻合，谱聚类成功从连接结构中还原出了社交网络的分裂




图 13. 分割无向图

邻接矩阵、度矩阵构造拉普拉斯矩阵，谱分解实现聚类

① 无向图的邻接矩阵 A 是对称矩阵，元素0、1表示两节点之间是否存在边

② 度矩阵 D 是对角矩阵，对角线元素是节点的度数，反映节点的活跃程度

③ 拉普拉斯矩阵 $L = D - A$ ，同样是对称矩阵，体现图的连接结构

④ 归一化处理消除节点度数差异，防止高连接节点主导聚类结果

⑤ 对归一化拉普拉斯矩阵做特征值分解（谱分解），选取最小的几个特征值对应的特征向量构造低维空间

⑥ 谱聚类：邻接矩阵→度矩阵→拉普拉斯矩阵→归一化→特征值分解→低维空间→聚类，一气呵成

本节关键词

邻接矩阵A 无向图对应的对称方阵，元素为1表示两节点之间有边

拉普拉斯矩阵L $L = D - A$ ，反映图的连接结构

谱分解 对实对称矩阵的特征值分解， $L = V\Lambda V^T$

度矩阵D 对角矩阵，对角线元素是节点的度数

归一化拉普拉斯矩阵 用D的负二分之一一次方缩放L，主对角线元素均为1

谱聚类 用拉普拉斯矩阵最小特征值对应的特征向量构造低维空间，再对节点聚类

延伸阅读

复习 · 15.3 转移矩阵

对比转移矩阵与拉普拉斯矩阵这两种从邻接矩阵、度矩阵出发构造的矩阵

复习 · 特征值分解

回顾实对称矩阵的谱分解 $V\Lambda V^T$

拓展阅读 · Zachary's Karate Club

1977年提出的经典社交网络数据集，可搜索了解更多社区发现算法

开源代码仓库

全书代码、图片: <https://github.com/Visualize-ML>

习题 Q1 – Q9

Q1 请用NetworkX加载内置的空手道俱乐部数据集（`karate_club_graph`），并绘制图1这幅无向图。

Q3 用Python根据邻接矩阵A计算度矩阵D，并验证D是否为对角矩阵。

Q5 用Python验证拉普拉斯矩阵L每一行元素之和是否都为0，并解释原因。

Q7 用Python对归一化拉普拉斯矩阵做特征值分解，验证所有特征值是否都非负。

Q9 用Python提取最小的2个非零特征值对应的特征向量，绘制类似图12的散点图。

Q2 用Python计算图1的邻接矩阵A，并验证A是否为对称矩阵。

Q4 用Python计算拉普拉斯矩阵 $L=D-A$ ，并验证L是否为对称矩阵。

Q6 用Python计算归一化拉普拉斯矩阵，并验证其主对角线元素是否均为1。

Q8 用Python把特征值按升序排列，绘制类似图10的柱状图。

习题 Q10 – Q17

Q10 用sklearn.cluster.SpectralClustering对图1数据直接聚类，并与手动实现的结果比较。

Q12 用Python计算拉普拉斯矩阵L的迹（trace），并解释它与节点总度数之间的关系。

Q14 用Python比较用拉普拉斯矩阵最小的2个特征值和最小的3个特征值构造低维空间，聚类结果是否相同。

Q16 用Python统计图1中两个社区（红色、蓝色）各自的节点数量，并与Zachary原始研究的分裂结果对比。

Q11 用Python验证正交矩阵V是否满足 $V@V^T$ 等于单位矩阵。

Q13 自己设计一个包含2个明显社区结构的小型无向图，用Python重复本节谱聚类的完整流程。

Q15 用Python验证拉普拉斯矩阵最小的特征值是否恒为0，并说明对应的特征向量有什么特点。

Q17 用Python绘制图1的度分布直方图，并讨论度分布是否符合无标度网络的特征。

习题 Q18 – Q25

Q18 用Python实现k-means聚类，直接对邻接矩阵的行向量聚类，并与谱聚类的结果做比较。

Q20 用Python验证：如果一个无向图有k个连通分量，拉普拉斯矩阵特征值0的重数是否恰好为k。

Q22 举例说明生活中还有哪些网络可以用谱聚类分析，比如社交网络、推荐系统、图像分割。

Q24 解释主成分分析选择最大特征值对应方向、谱聚类选择最小特征值对应方向，两者出发点有何不同。

Q19 解释归一化拉普拉斯矩阵与原始拉普拉斯矩阵相比，在聚类效果上有什么优势。

Q21 用Matplotlib绘制邻接矩阵A、拉普拉斯矩阵L、归一化拉普拉斯矩阵的热图，并比较三者的差异。

Q23 用Python为图1数据集分别选取前2、前3个最小特征值对应的特征向量，比较低维空间的可视化效果。

Q25 结合本节内容，总结从邻接矩阵到谱聚类的完整流程，并说明每一步涉及的线性代数工具。

10个和AI互动的Prompt

- 1 解释谱聚类的基本流程：从邻接矩阵、度矩阵到拉普拉斯矩阵、归一化拉普拉斯矩阵，再到特征值分解。
- 2 解释拉普拉斯矩阵 $L=D-A$ 的构造方式，以及为什么它能反映图的连接结构。
- 3 解释为什么需要对拉普拉斯矩阵做归一化处理，归一化前后聚类效果有什么不同。
- 4 解释为什么谱聚类选取的是最小特征值对应的特征向量，而主成分分析选取的是最大特征值对应的方向。
- 5 解释Zachary's Karate Club这个经典数据集的来历，以及它为什么常被用来检验社区发现算法。

10个和AI互动的Prompt

6 解释拉普拉斯矩阵特征值为0对应的特征向量有什么特殊含义，与图的连通性有什么关系。

7 举例说明生活中还有哪些场景可以用谱聚类分析，比如社交网络、图像分割、推荐系统。

8 解释度矩阵、邻接矩阵、拉普拉斯矩阵三者之间的关系，以及每一个矩阵反映了图的哪些性质。

9 比较谱聚类与k-means聚类的异同，说明谱聚类在处理非凸形状簇时的优势。

10 回顾整本《线性代数不难》的学习历程，说明从向量、矩阵到特征值分解、谱聚类，线性代数是如何逐步搭建起解决实际问题的工具箱的。

把线性代数学懂、用好

- ① 把线性代数学懂、用好，是《线性代数不难》的追求；希望在Python编程、几何化思维、Manim数学动画的助力下，让线性代数真正“不难”
- ② 线性代数的学习不应是枯燥的数字游戏，也不该是死记硬背公式的痛苦旅程，而应是一场几何视觉的盛宴，一次深入数字丛林的探险
- ③ 真正掌握线性代数，意味着能以更高的视角审视数据、模型、现象与世界；本书也只是一个起点，愿它能在大家心中种下一颗种子
- ④ 数学之美，不在于复杂，而在于透过抽象洞察背后的秩序与本质；愿每一位读者都能带着好奇心，将线性代数化为探索世界的不懈力量

感谢观看 · 全书完

《线性代数不难》· 数学之美，不在于复杂，而在于透过抽象，通过几何洞察背后的秩序与本质






线性代数 | 生姜 DrGinger (作者、脚本) · 崔崔 CuiCui (视频) | 开源资源: <https://github.com/Visualize-ML>
YouTube: https://www.youtube.com/@DrGinger_Jiang | B站: <https://space.bilibili.com/513194466>

数学

数学基础

线性代数

概率统计



Python编程

数据可视化

工具

数据分析
图和网络

回归、降维
分类、聚类

实践

